粒子滤波

应用最广泛，原理最复杂，术语最多

$$w_k^{(i)} = w_{k-1}^{(i)} \frac{p(y_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})}{q(x_k^{(i)}|x_{k-1}^{(i)})}$$

MCMC　　IS　　SIS　　SIR　　提议分布　　重采样

第九讲：理论，第十讲：代码，第十一讲：采样方法

粒子滤波从此没有任何秘密

从贝叶斯滤波开始

$X_k = f(X_{k-1}) + Q_k$

$Y_k = h(X_k) + R_k$　　X_0、$Q_1 \cdots Q_k$、$R_1 \cdots R_k$ 互相独立，$Q_1 \cdots Q_k$、$R_1 \cdots R_k$ 满足 Normal distribution

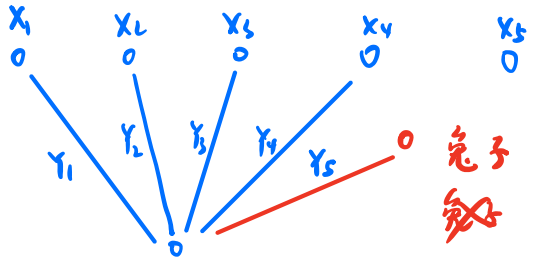
~~Markov~~　　~~Mento Carlo~~　　不需要那么复杂

slam　请专注于非线性优化 + 激光slam，不要学pf

↓

图优化

滤波在slam已过时，无法处理动态场景



逆推是根据上一时刻估算下一时刻

滤波怎么处理：设 $R_1 \cdots R_k$ 为传感器噪声方差，把 R_5 调大一点

f_0、f_k 都是事先设定的，无人可以未卜先知，能预测它什么时候来

动态环境可能会出现传感器精度大幅下降，但是无人可以未卜先知，把那些不好的数据干掉

slam → 非线性优化

粒子滤波：静态环境，动态可预测环境　汽车 $a_y > 0.4g$ 轮胎非线性

电池电量估算，视频跟踪，封闭环境导航（激光雷达+pf　slam）≠ Gmapping

bayes　filter

初值　$X_0 \xrightarrow{pdf} f_0^+$

预测：$f_k^-(x) = \int_{-\infty}^{+\infty} f_Q[x - f(v)] f_{k-1}^+(v)\, dv$

更新：$f_k^+(x) = \eta f_R[y_k - h(x)] f_k^-(x)$　　$\eta = \left(\int_{-\infty}^{+\infty} f_R[y_k - h(x)] f_k^-(x)\, dx\right)^{-1}$

估计：$\hat{x}_k^+ = \int_{-\infty}^{+\infty} x f_k^+(x)\, dx$　　1-6讲

缺点：无穷积分，一般无解析解

~~Monte Carlo integral~~

由大数定律引发的遐想

大数定律　设 X 为随机变量，E(X) 存在，对 X 多次做随机试验，做 n 次

试验结果记为 $x_1, x_2, x_3 \cdots x_n$，则有

$$\lim_{n\to\infty} P\left(\left|\frac{1}{n}\sum_i x_i - E(X)\right| < \varepsilon\right) = 1$$

暗示了什么？ 当 n 足够大时，$\frac{1}{n}\sum_i x_i \approx E(X)$ (大小写)

$E(X)=\int_{-\infty}^{+\infty} x f(x)dx \Rightarrow$ 当 $n\to\infty$ 时 $\frac{1}{n}\sum_i x_i = \int_{-\infty}^{+\infty} x f(x)dx$

$\delta(x) \Rightarrow \int_c^d f(x)\delta(x-a)=f(a) \quad a\in(c,d)$

$\frac{1}{n}\sum_i x_i = \frac{1}{n}(x_1+x_2+\cdots x_n)$ ∵ $x_1 \cdots x_n$ 为数，数是可以排序的

不妨设 $-\infty < x_1 < a_1 < x_2 < a_2 < x_3 < a_3 < \cdots < x_n < +\infty$

$x_1 = \int_{-\infty}^{a_1} x\delta(x-x_1)dx \quad x_2=\int_{a_1}^{a_2} x\delta(x-x_2)dx \cdots x_n=\int_{a_{n-1}}^{+\infty} x\delta(x-x_n)dx$

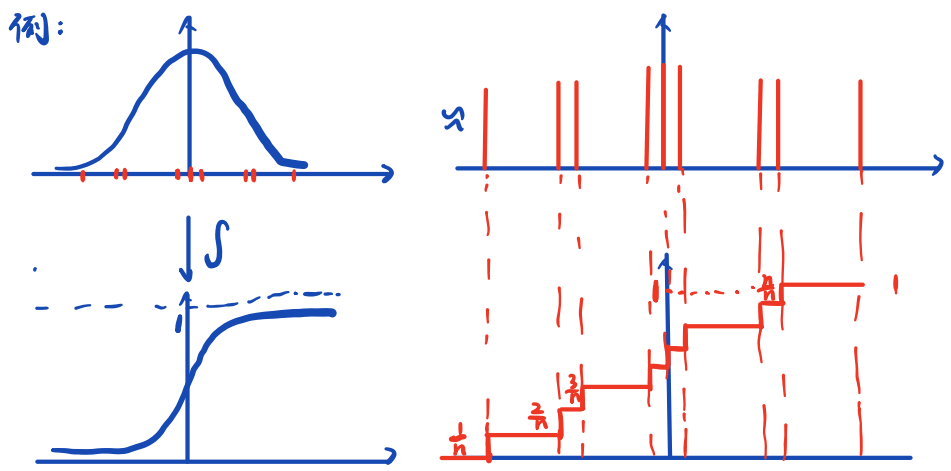
∴ $\frac{1}{n}\sum_i x_i = \frac{1}{n}\left(\int_{-\infty}^{a_1}+\int_{a_1}^{a_2}+\cdots+\int_{a_{n-1}}^{+\infty}\right)$

$$=\frac{1}{n}\int_{-\infty}^{+\infty} x\left[\sum_i \delta(x-x_i)\right]dx = \int_{-\infty}^{+\infty} x f(x)dx$$

$f(x)$ 为 X 的 pdf

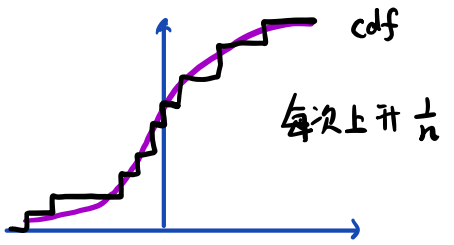
大数定律 当 $n\to\infty$ 时 $f(x) \approx \frac{1}{n}\sum_i \delta(x-x_i)$ 对积分

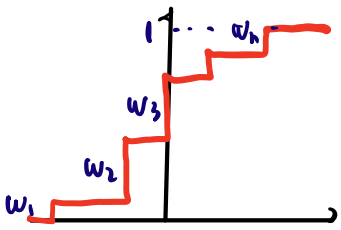
大数定律暗示了可以用一堆粒子来近似概率密度，这就是粒子滤波



点越多越精确

缺点：需要大量粒子，如何让少量粒子表示 pdf





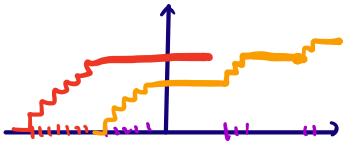
引入权重的概念，让少量粒子有较高的权重

$f(x) \approx \frac{1}{n}\sum_i \delta(x-x_i) = \sum_i \frac{1}{n}\delta(x-x_i)$ 每个粒子的权重都是 $\frac{1}{n}$

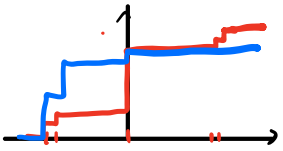
$= \sum_i w_i \delta(x-x_i)$ $\sum_i w_i = 1$

粒子的位置与权重完全决定了 cdf → pdf

$x_1 \cdots x_2 \cdots x_n$ $w_i = \frac{1}{n}$



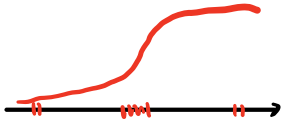
位置影响 cdf



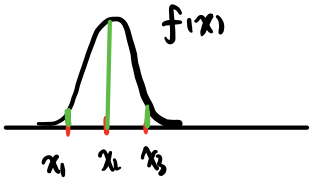
权重影响 cdf

大数定律：$n \to \infty$ $f(x) = \frac{1}{n}\sum_i \delta(x - x_i)$

∵ x_i 是从 $f(x)$ 采样出来的，x_i 的位置天然满足概率分布的规律



w_i 如何分配



原则，pdf 大的，w_i 高

$$w_i = \frac{f(x_i)}{f(x_1) + f(x_2) + f(x_3)}$$

按比例分配，满足归一化 $\sum w_i = 1$

也可以 $w_i = \frac{1}{n}$，但是 n 要足够大（50个以上）

也可以综合：n 大，$w_i = \frac{f(x_i)}{\sum_i f(x_i)}$

贝叶斯滤波　X_0 的 pdf 为 $f_0(x)$，在 $f_0(x)$ 中采了 n 个样本（怎么采样？）

采样很难，假设 X_0 是一个正态分布，Matlab 可以直接生成正态随机数，C/C++ 可以调用库

设采集的样本为 $x_0^{(1)}$，$x_0^{(2)}$，… $x_0^{(n)}$

设 $f_0(x) = \sum_i w_0^{(i)} \delta[x - x_0^{(i)}]$　　$w_0^{(i)}$ 可以为 $\frac{1}{n}$，也可以按比例分配

则 $f_1^-(x) = \int_{-\infty}^{+\infty} f_Q[x - f(w)] f_0(w)\, dw = \sum_i w_i f_Q[x - f(x_0^{(i)})]$　无δ

$f_1^+(x) = \eta f_R[y - h(x)] f_1^-(x)$　　粒子去哪里了？

无δ

无δ无法递推

通过 $f_1^-(x)$ 生成一堆粒子，理论上 $f_1(x) = \sum_i w_i f_Q[x - f(x_0^{(i)})]$ 可以采样，也可以计算出新的 w

但是太困难

怎么做？⇒ $f_Q[x - f(x_0^{(i)})]$，假设 Q 为 Normal distribution

$$f_Q[x - f(x_0^{(i)})] = (2\pi Q)^{-\frac{1}{2}} e^{-\frac{[x - f(x_0^{(i)})]^2}{2Q}} \sim N(f(x_0^{(i)}), Q)$$

$N(f(x_0^{(i)}), Q) \xrightarrow{F.T} e^{i f(x_0^{(i)}) t - \frac{Q}{2} t^2}$

F.T: $g(t) = \int_{-\infty}^{+\infty} f(x) e^{itx} dx$

i.F.T $f(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} g(t) e^{-itx} dt$

$N(\mu, \sigma^2) \xrightarrow{F.T} e^{i\mu t - \frac{\sigma^2}{2} t^2}$

$N(f(x_0^{(i)}), Q) \xrightarrow{F.T} e^{if(x_0^{(i)})t - \frac{Q}{2}t^2} = e^{if(x_0^{(i)})t} \cdot e^{-\frac{Q}{2}t^2}$

$e^{if(x_0^{(i)})t} \xrightarrow{i.F.T} \delta(x - f(x_0^{(i)}))$ $\int_{-\infty}^{+\infty} \delta(x - f(x_0^i)) e^{ixt}\, dx = e^{if(x_0^i)t}$

$e^{-\frac{Q}{2}t^2} \xrightarrow{i.F.T} N(0, Q)$

$\delta(x - f(x_0^{(i)}))$ 是必然事件 $X = f(x_0^{(i)})$ 的 pdf

$N(0, Q)$ 为 Q 的 pdf

定理：若 X pdf为 f，Y 的 pdf为 g，X, Y 独立，则 $Z = X + Y$ 的 pdf $= f * g$

设 Z 的 pdf 为 h，则 $h = f * g$

卷积性质 设 G为 F.T G^{-1}为 iFT

则 $G(h) = G(f) \cdot G(g)$

设 A 的 pdf $f_A = f_Q[x - f(x_0^{(i)})]$ $G(f_A) = e^{if(x_0^{(i)})t} \cdot e^{-\frac{Q}{2}t^2}$

而 $G^{-1}(e^{if(x_0^{(i)})t}) = \delta(x - f(x_0^{(i)}))$ $G^{-1}(e^{-\frac{Q}{2}t^2}) = (2\pi Q)^{-\frac{1}{2}} e^{-\frac{x^2}{2Q}}$

设 X 的 pdf 为 $f_X = \delta(x - f(x_0^{(i)}))$，Y 的 pdf 为 $f_Y = (2\pi Q)^{-\frac{1}{2}} e^{-\frac{x^2}{2Q}}$，X, Y 独立

$G(f_A) = G(f_X) \cdot G(f_Y) \Rightarrow A = X + Y$

X 为必然事件，$Y \sim N(0, R)$，X, Y 独立

如何去生成粒子 $f_1(x) = \sum_i w_0^{(i)} f_Q[x - f(x_0^{(i)})]$

对于每一个 $f_Q[x - f(x_0^{(i)})]$ 可以看作是一个必然事件 $X = f(x_0^{(i)})$ 与一个随机数 $Y \sim N(0, Q)$ 的叠加

$\bar{f}_1(x)$ 粒子 $X_1^{-(1)}$ $X_1^{-(2)}$ … $X_1^{-(n)}$

$$X_1^{-(i)} = f(x_0^{(i)}) + v \qquad v \text{ 为 } \sim N(0, R) \text{ 的一个随机数}$$

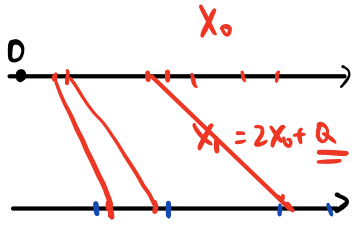
例：$X_1 = 2X_0 + Q \qquad Q \sim N(0,1)$

设 $X_0 \sim N(1,1)$ 样本 $x_0^{(1)} = 0.$ $x_0^{(2)} = 0.1$, $x_0^{(3)} = -0.1$

$X_1^{-(i)} = f(x_0^{(i)}) + v$ $\quad x_1^{-(0)} = 2\cdot 0 + 0.12$ $\quad x_1^{-(1)} = 0.1\times 2 + 0.08$ $\quad x_1^{-(2)} = -0.1\times 2 + 0.3$

$\bar{f}_1(x) = \sum_i^n w_0^{(i)} f_Q[x - f(x_0^{(i)})]$ 对于每一个 $f_Q[x - f(x_0^{(i)})]$，生成一个粒子即可

此时 $x_1^{-(i)} = f(x_0^{(i)}) + Q$ ，本质是改变了粒子的位置，并未改变粒子的权重



粒子滤波算法

1. 设初值 $X_0 \sim N(m, \sigma^2)$

2. 生成 X_0 的样本 $x_0^{(1)} \cdots x_0^{(n)}$

3. 生成 X_0 样本对应权重，$w_0^{(i)}$，可以都为 $\frac{1}{n}$，也可以为 $\frac{f(x_0^{(i)})}{\sum_i f(x_0^{(i)})}$ $f(x)$ 为 X_0 的 pdf

4. 生成 X_1^- 的样本，$x_1^{-(i)} = f(x_0^{(i)}) + Q$，Q 为一个服从 $N(0, Q)$ 的随机数

5. $\bar{f}(x) = \sum_{i=1}^n w_0^{(i)} \delta(x - x_1^{-(i)})$ 此时改变了粒子的位置，但未改变权重

6. 预测步结束

7. 观测到了一个数据 y_1

8. $f_1^+(x) = \eta f_R[y_1 - h(x)] f_1^-(x) = \sum_{i=1}^{n} \eta f_R[y_1 - h(x)] w_0^{(i)} \delta(x - x_1^{-(i)})$

$$= \sum_{i=1}^{n} \eta f_R[y_1 - h(x_1^{-(i)})] w_0^{(i)} \delta(x - x_1^{-(i)})$$

$$f(x)\delta(x-a) = \begin{cases} 0 & x \neq a \\ f(a)\cdot\infty & x = a \end{cases}$$

$$f(a)\delta(x-a) = \begin{cases} 0 & x \neq a \\ f(a)\cdot\infty & x = a \end{cases}$$

$\therefore f(x)\delta(x-a) = f(a)\delta(x-a)$

设 $w_1^{(i)} = f_R[y_1 - h(x_1^{(i)-})] w_0^{(i)}$ $\therefore f_1^+(x) = \eta \sum_{i=1}^{n} w_1^{(i)} (x - x_1^{-(i)})$

更新步并未改变粒子位置，但是改变了粒子的权重

9. $\eta = (\sum_i w_1^{(i)})^{-1}$ 归一化

$x_1^{(i)-} \Rightarrow x_1^{(i)}$

粒子滤波完整算法

1. 给初值 $x_0 \sim N(\mu, \sigma^2)$

2. 生成 $x_0^{(i)}$，$w_0^{(i)} = \frac{1}{n}$

3. 预测步，生成 $x_1^{(i)} = f(x_0^{(i)}) + v$，$v$为$\sim N(0, Q)$的随机数，共$n$个，

4. 更新步，设观测值为 y_1，生成 $w_1^{(i)} = f_R[y - h(x_1^{(i)})] \cdot w_0^{(i)}$

5. 将 $w_1^{(i)}$ 归一化，$w_1^{(i)} = \frac{w_1^{(i)}}{\sum w_1^{(i)}}$

6. 此时，得到新的粒子 $x_1^{(i)}$，新的权重 $w_1^{(i)}$

7. 在由预测步生成 $x_2^{(i)} = f(x_1^{(i)}) + v$

8. 在由更新步生成 $w_2^{(i)} = f_R[y_2 - h(x^{(i)})] w_1^{(i)}$，归一化

9. 如此递推

总结：1 由大数定律，暗示了 pdf 可由带权重的粒子表示

2. 粒子数量，粒子位置，粒子权重完全决定了 cdf，也决定了 pdf

3. 预测步改变粒子位置

4. 更新步更新粒子权重