主流VIO综述及VINS解析

崔华坤 2019.2.22

深蓝学院
shenlanxueyuan.com

目录

1 VIO的研究意义

2 VIO的求解：BA、G-N和因子图

3 VIO的分类

4 用因子图来解释各VIO的后端

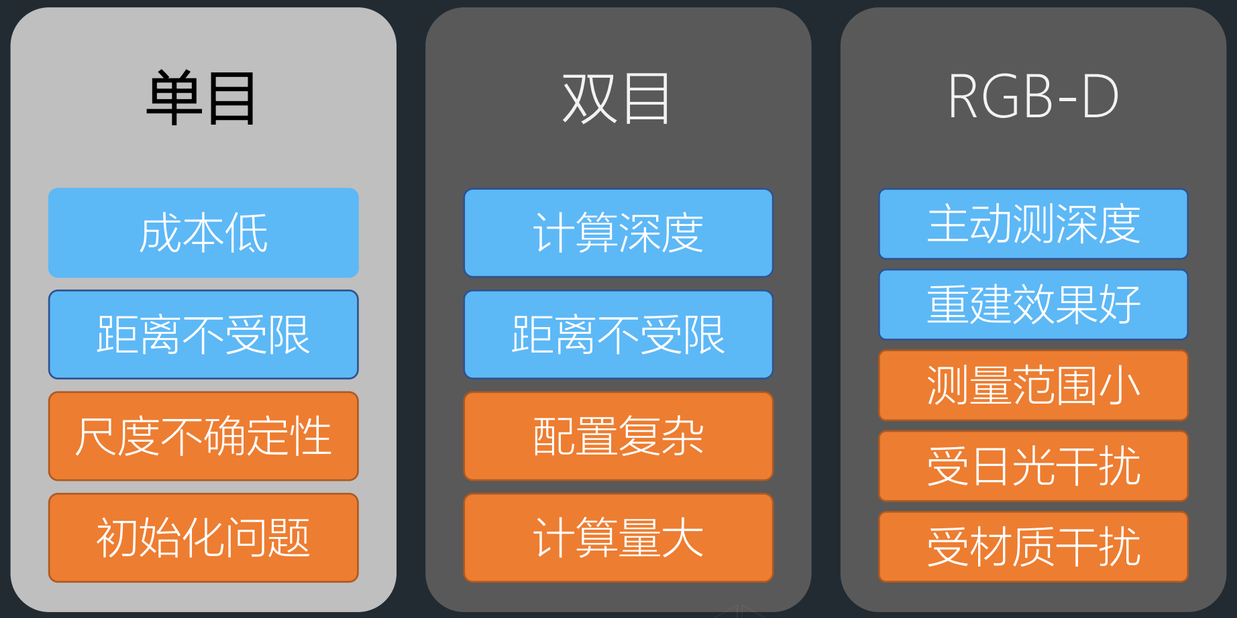
- MSCKF、ROVIO、VINS、VI-ORB、ICE-BA

5 VINS论文和代码解析

- IMU预积分
- 视觉约束
- 边缘化
- 联合约束

深蓝学院
shenlanxueyuan.com

VIO的研究意义：主要讨论单目+IMU



VIO 各自的缺点及互补

Camera	单目相机无法解决尺度问题 在纹理少的区域无法工作 快速运动时图像模糊 动态场景会有错误匹配
IMU	纯IMU预测会有漂移 角度漂移相对时间t是线性的 位置漂移是t^2级别的

BundleAdjustment

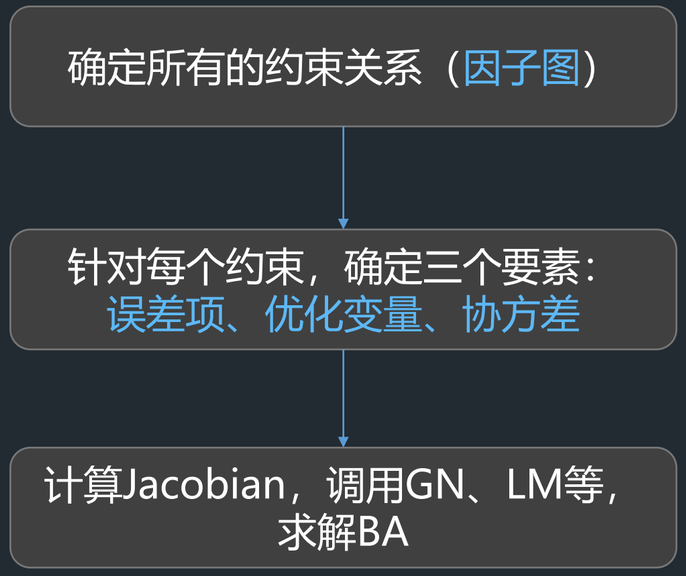
定义：通过优化相机位姿和特征点的空间位置，使得每条光束都能打到光心；

作用：BA是SLAM后端的核心，SLAM其实就是一个BA问题，理解BA对于分析现有问题和建模新问题等都很有帮助；

但是理解BA并不表示SLAM效果就好，SLAM最终结果的好坏很大取决于数据关联的好坏；

核心：误差项、优化变量、协方差

难点：李群、李代数、四元数的Jacobian，一通则百通，也可借鉴g2o写好的点和边，但要注意坐标系转换关系。



一个SLAM问题求解的整体思路

高斯牛顿法

深蓝学院 shenlanxueyuan.com

目标函数：

$$\Delta x^* = arg\min_x \|e(x+\Delta x)\|_P^2$$

$$= \min_x e(x+\Delta x)^T P^{-1} e(x+\Delta x)$$

误差项：

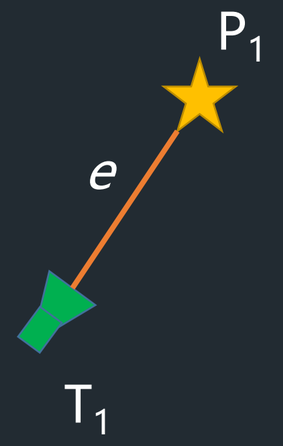
$$e(x+\Delta x) \approx e(x) + J(x)\Delta x$$

令目标函数关于Δx的导数为0，
得到高斯牛顿方程，即增量方程：

$$J^T P^{-1} J \Delta x = -J^T P^{-1} e$$

H　　b

举例1：一次观测

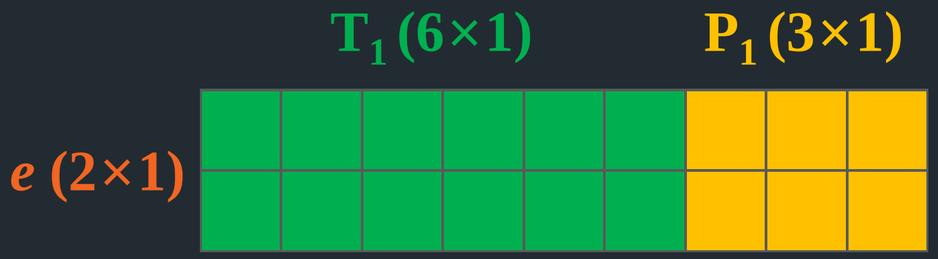


1. 误差项：e 为像素平面上的重投影误差 (2×1)
2. 优化变量：x 为相机位姿 $\mathbf{T}_1$ (6×1)、路标点 $\mathbf{P}_1$ (3×1)
3. 协方差：$\mathbf{P}$ 为像素误差 (2×2)

深蓝学院 shenlanxueyuan.com

Jacobian矩阵：

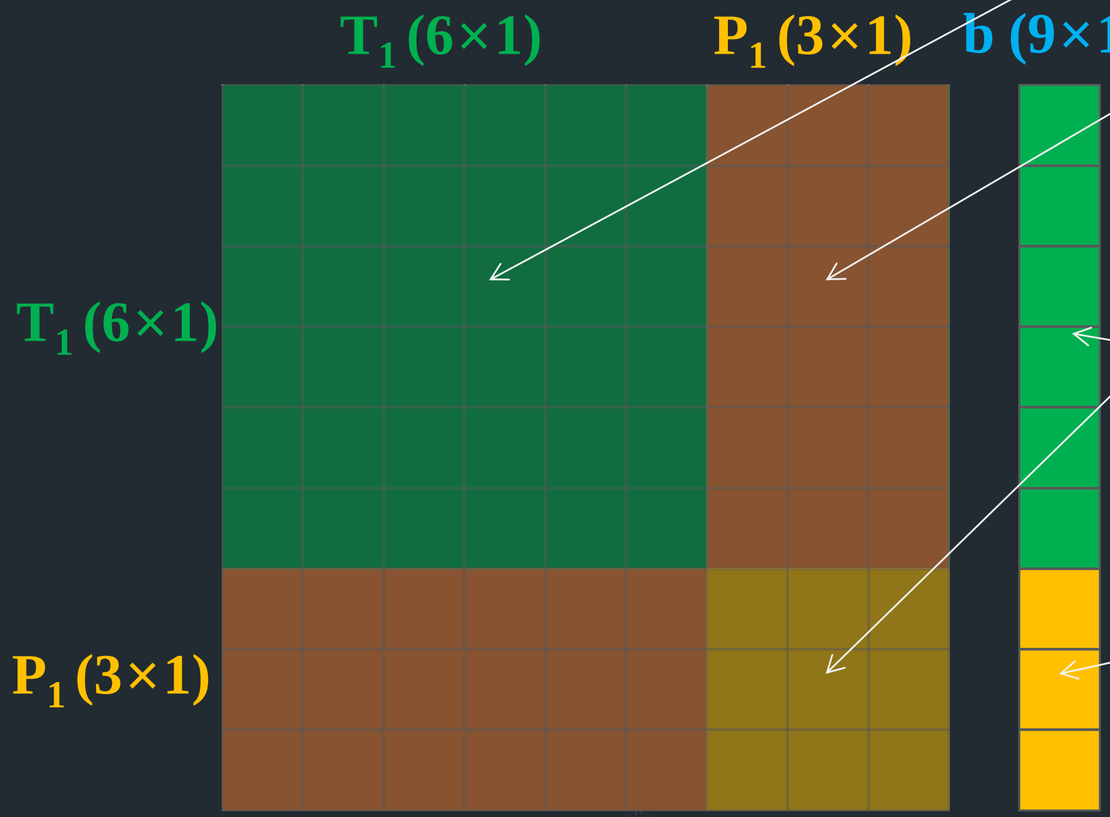
$$J^{2\times9} = \frac{\partial e}{\partial x} = \begin{bmatrix} \frac{\partial e}{\partial T_1} & \frac{\partial e}{\partial P_1} \end{bmatrix} = [J_T{}^{2\times6} \quad J_P{}^{2\times3}]$$



$$J_T{}^{2\times6} = \frac{\partial e}{\partial T_1} \qquad J_P{}^{2\times3} = \frac{\partial e}{\partial P_1}$$

举例1：Hession

$$H^{9\times9} = J^T P^{-1} J = \begin{bmatrix} J_T{}^T P^{-1} J_T & J_T{}^T P^{-1} J_P \\ J_P{}^T P^{-1} J_T & J_P{}^T P^{-1} J_P \end{bmatrix} = \begin{bmatrix} H_{TT}{}^{6\times6} & H_{TP}{}^{6\times3} \\ H_{PT}{}^{3\times6} & H_{PP}{}^{3\times3} \end{bmatrix}$$

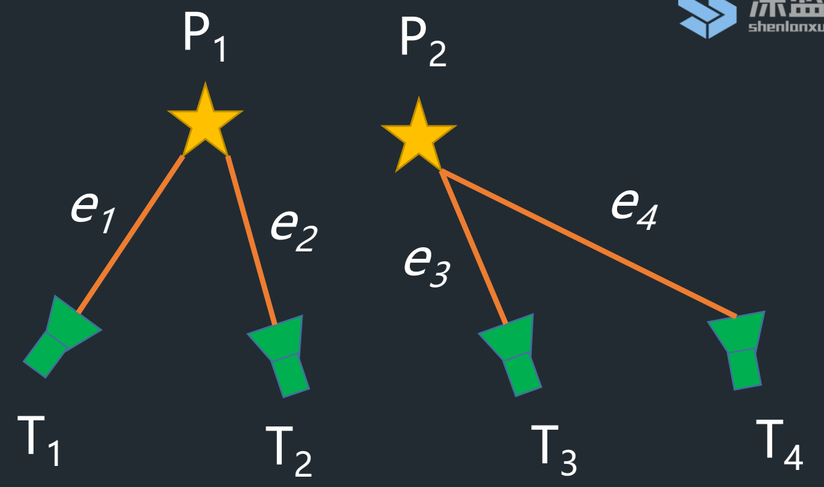


$$b^{9\times1} = -J^T P^{-1} e = \begin{bmatrix} -J_T{}^T P^{-1} e \\ -J_P{}^T P^{-1} e \end{bmatrix} = \begin{bmatrix} b_T{}^{6\times1} \\ b_P{}^{3\times1} \end{bmatrix}$$

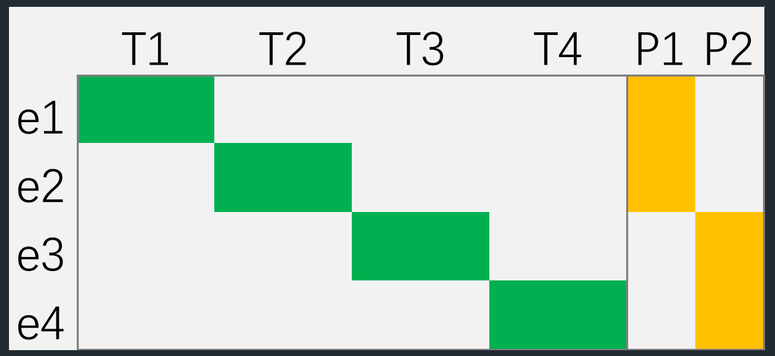
深蓝学院 shenlanxueyuan.com

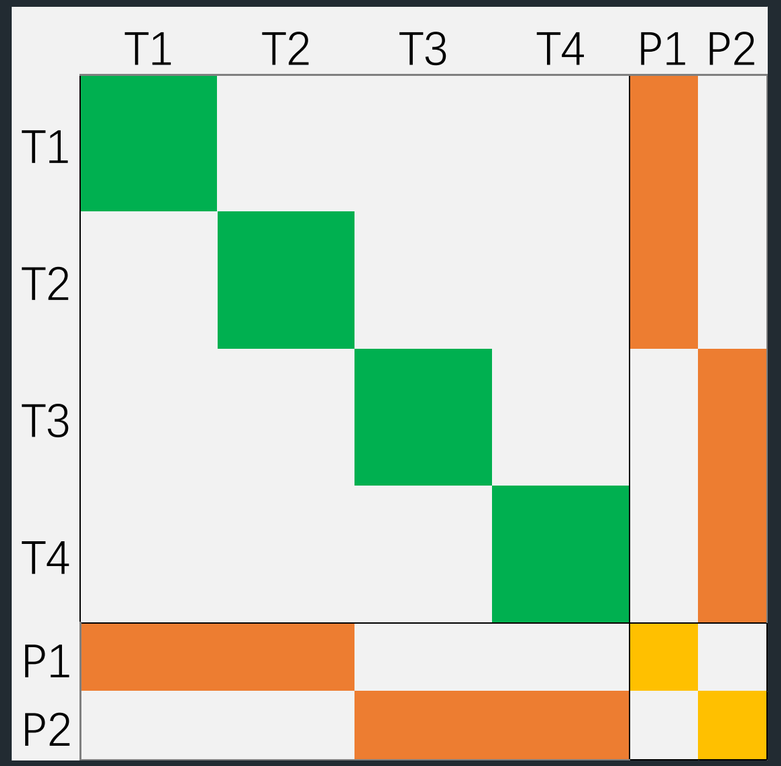
举例2：多次观测

1. 误差项：e_1、e_2、e_3、e_4
2. 优化变量：T_1、T_2、T_3、T_4、P_1、P_2
3. 协方差：P 为像素误差 (2×2)



Jacobian

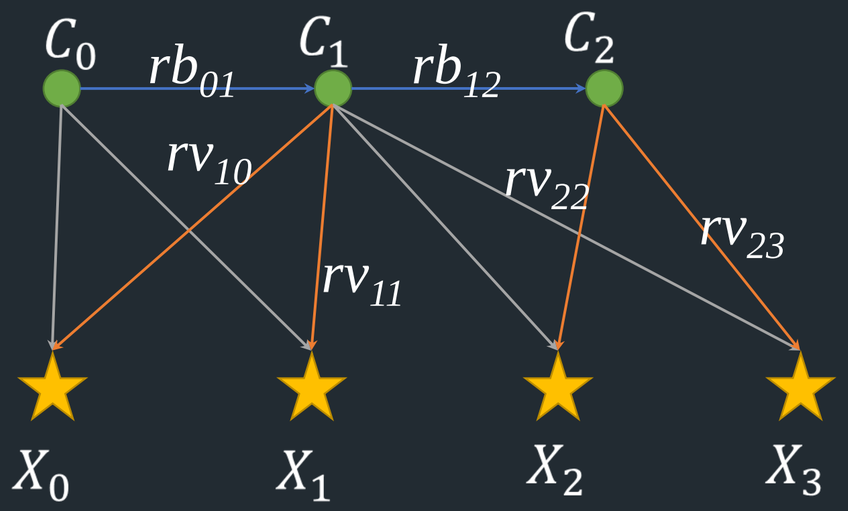


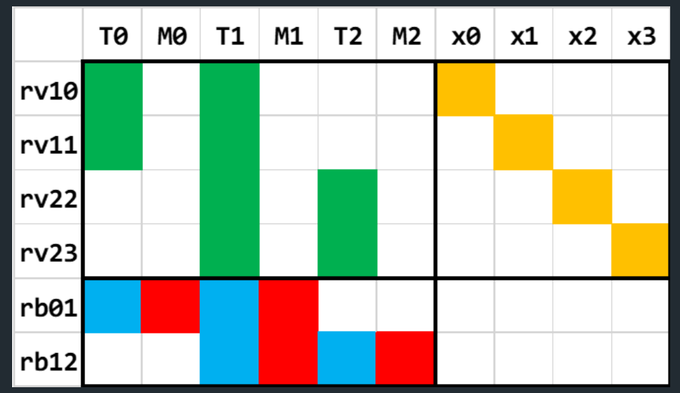


Hession

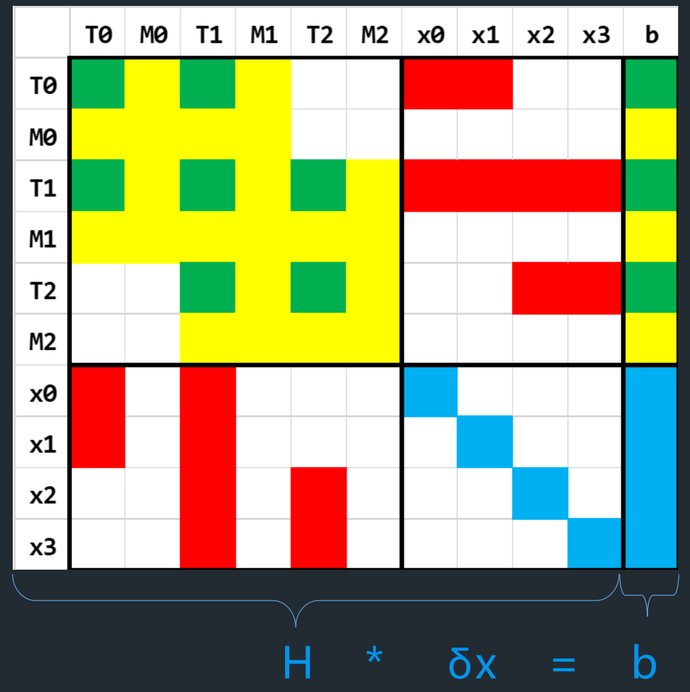
举例3：逆深度+VIO

$$C_0 = [T_0 \quad M_0] = [R|t \quad vBaBg]$$





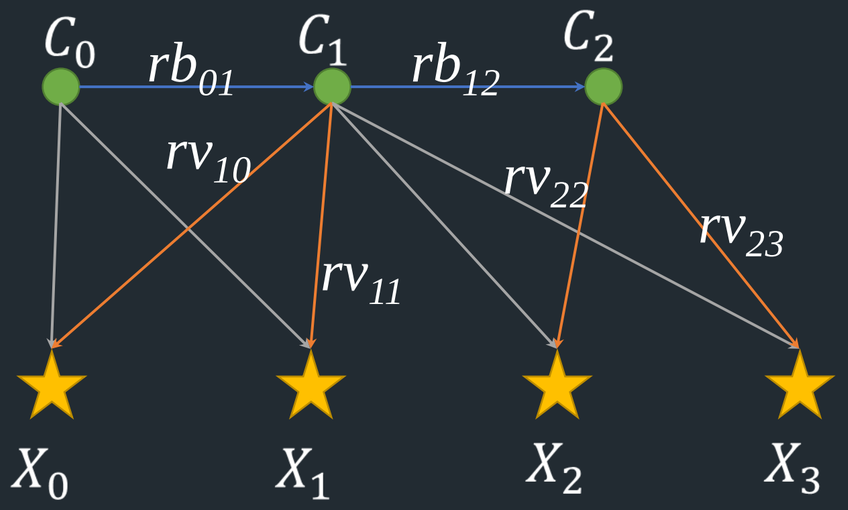
Jacobian

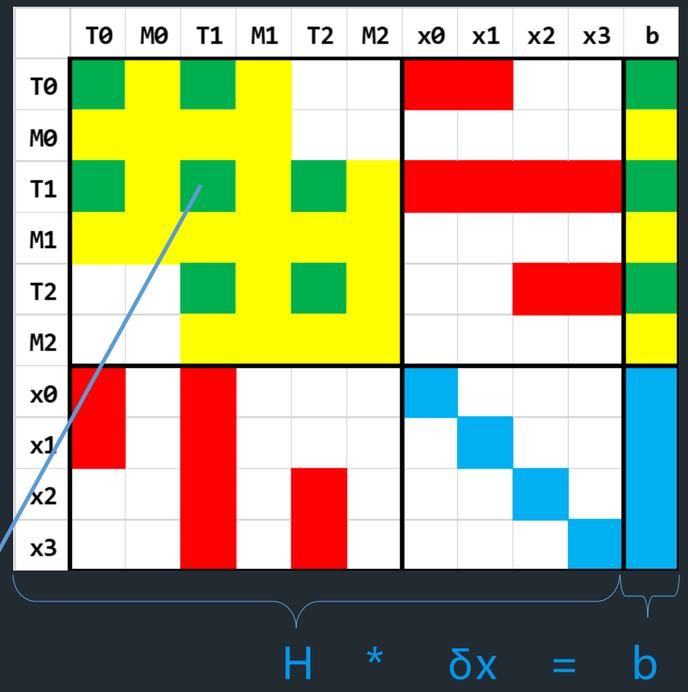


H * δx = b

绿色小块同时受视觉和 IMU 共同约束影响
黄色小块仅受 IMU 约束影响
红色和蓝色小块仅受视觉约束影响

举例3：逆深度+VIO





$$H_{T_1T_1} = \left(\frac{\partial r_{v_{10}}}{\partial T_1}\right)^T \left(\frac{\partial r_{v_{10}}}{\partial T_1}\right) + \left(\frac{\partial r_{v_{11}}}{\partial T_1}\right)^T \left(\frac{\partial r_{v_{11}}}{\partial T_1}\right) + \left(\frac{\partial r_{v_{22}}}{\partial T_1}\right)^T \left(\frac{\partial r_{v_{22}}}{\partial T_1}\right) + \left(\frac{\partial r_{v_{23}}}{\partial T_1}\right)^T \left(\frac{\partial r_{v_{23}}}{\partial T_1}\right)$$
$$+ \left(\frac{\partial r_{B_{01}}}{\partial T_1}\right)^T \left(\frac{\partial r_{B_{01}}}{\partial T_1}\right) + \left(\frac{\partial r_{B_{12}}}{\partial T_1}\right)^T \left(\frac{\partial r_{B_{12}}}{\partial T_1}\right)$$

深蓝学院 shenlanxueyuan.com

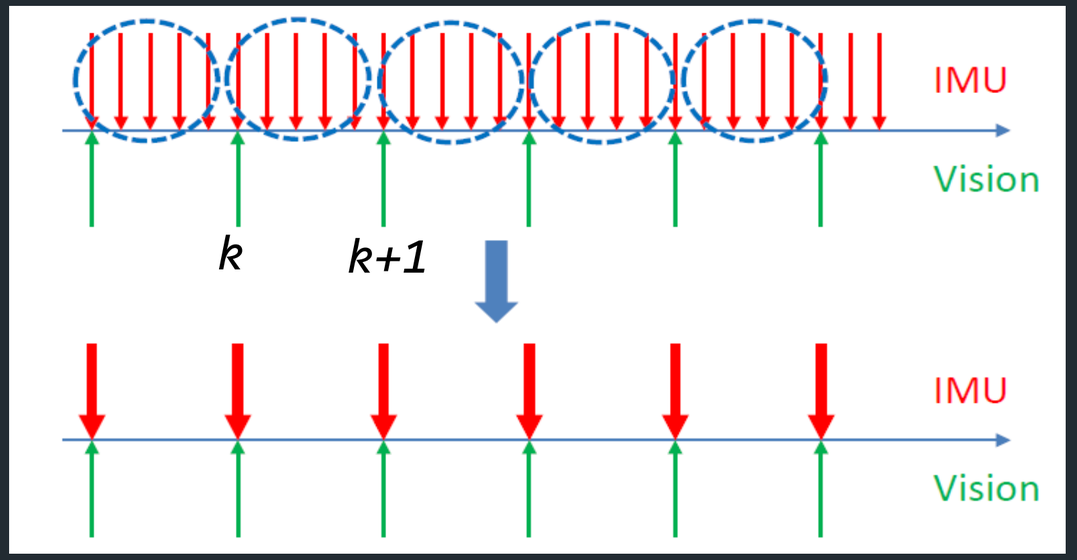
EKF滤波和优化

1. EKF滤波相当于只迭代一次的优化，区别是滤波仅考虑上一帧的影响，而优化则考虑所有帧的影响
2. 多次优化精度比滤波高，但效率低于滤波，因优化可以迭代多次，不断优化线性化点，使误差最小。

深蓝学院 shenlanxueyuan.com

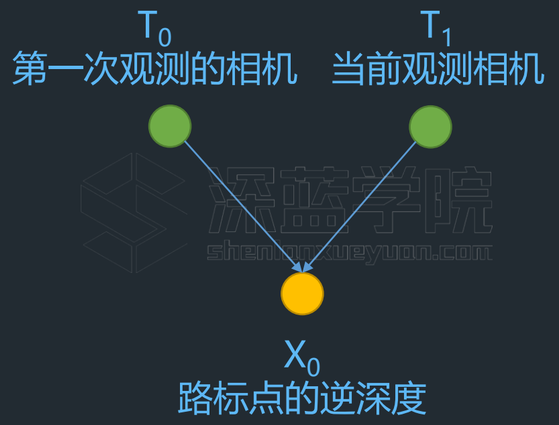
IMU预积分

1. 积分下一个时刻的PVQ作为视觉初始值；
2. 预积分相邻帧的PVQ变化量，作为IMU约束；
3. 计算IMU误差的协方差，和Jacobian。

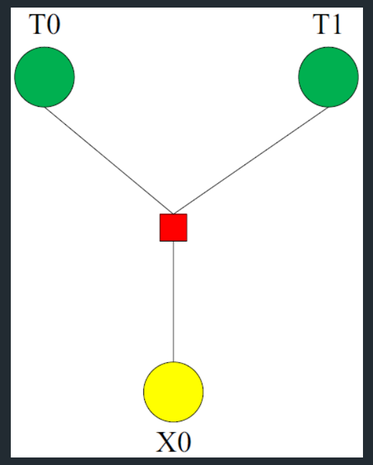


因子图

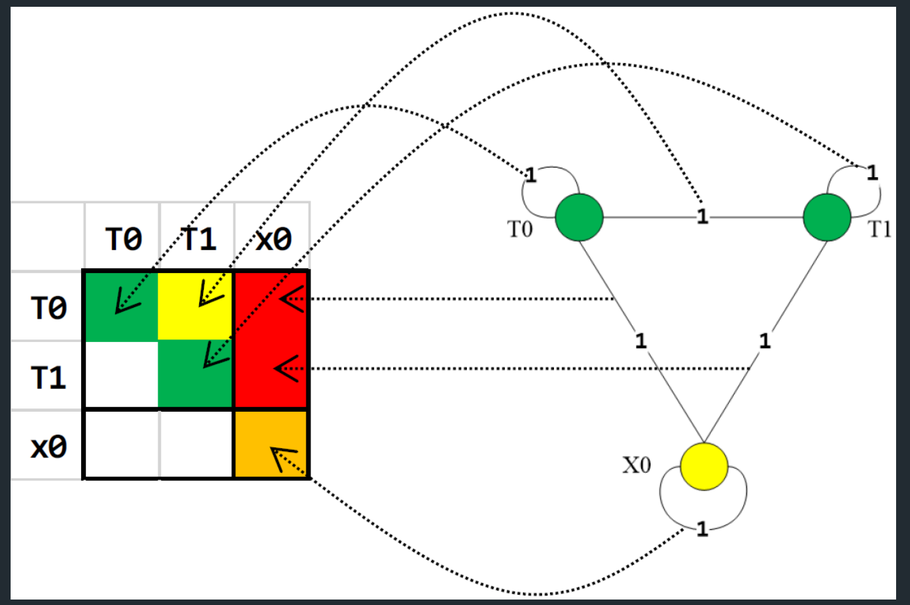
因子图中方块表示因子，圆圈表示优化变量。一个因子表示一个约束，即表示一个误差项，与之相连的圆圈是与该误差项相关的优化变量。



逆深度视觉约束：
重投影误差（与三个优化变量有关）



视觉因子



因子图与Hession的对应关系

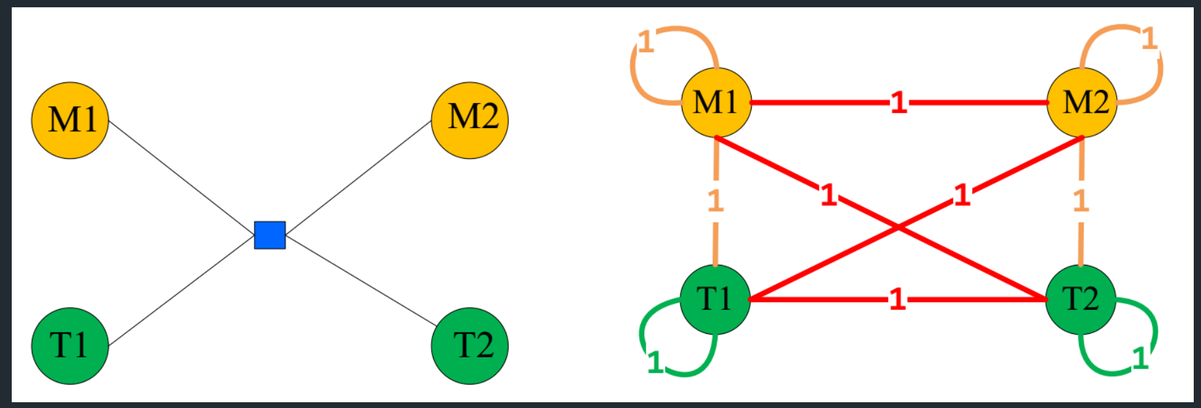
$$H_{T_0T_0} = \left(\frac{\partial e}{\partial T_0}\right)^T P^{-1} \left(\frac{\partial e}{\partial T_0}\right)$$

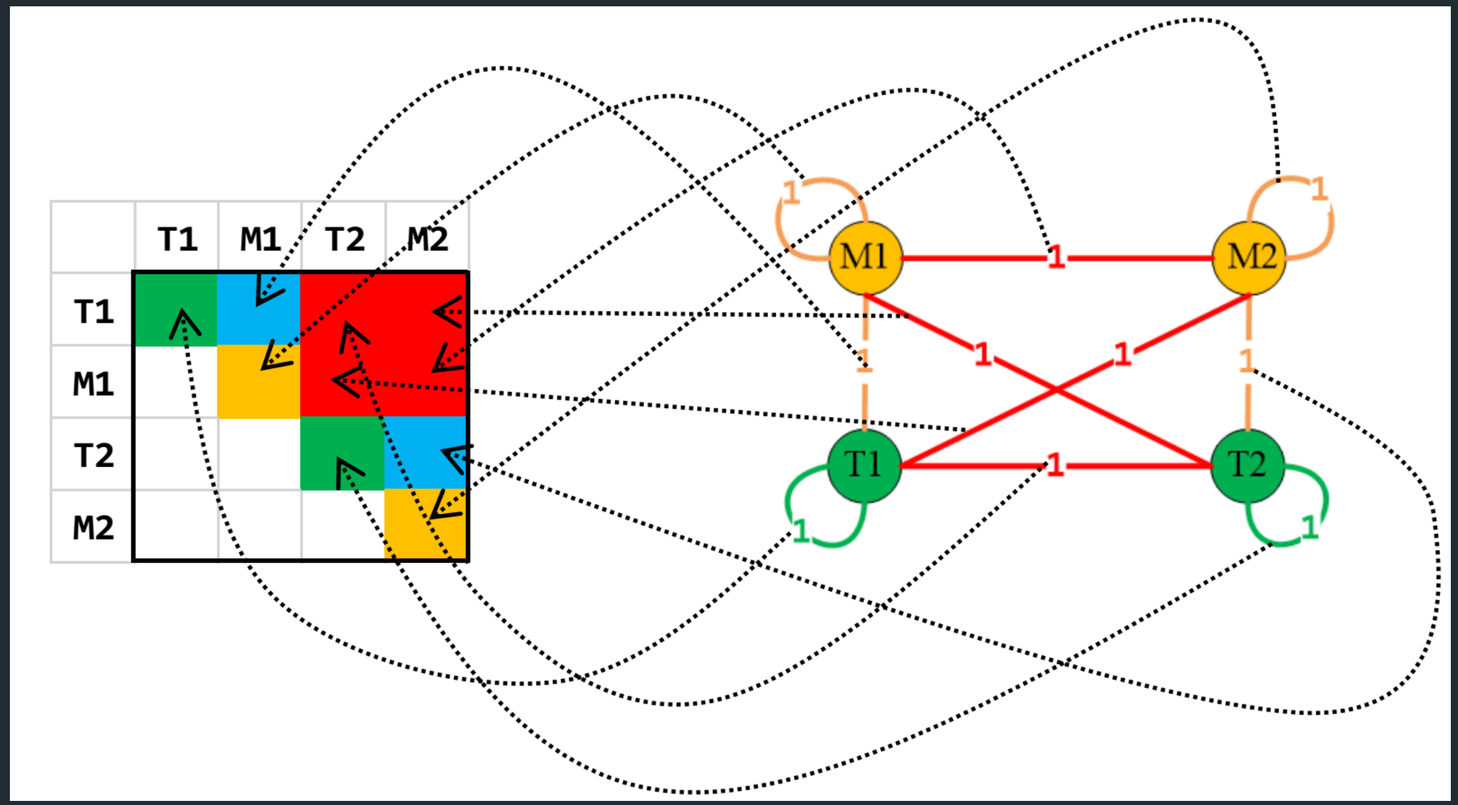
可参考《概率机器人》、《机器人感知》

因子图——IMU约束

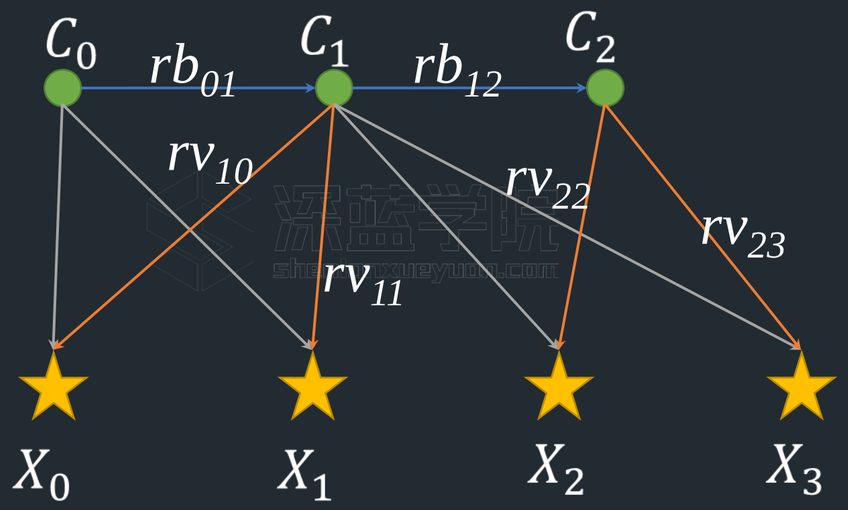
深蓝学院 shenlanxueyuan.com

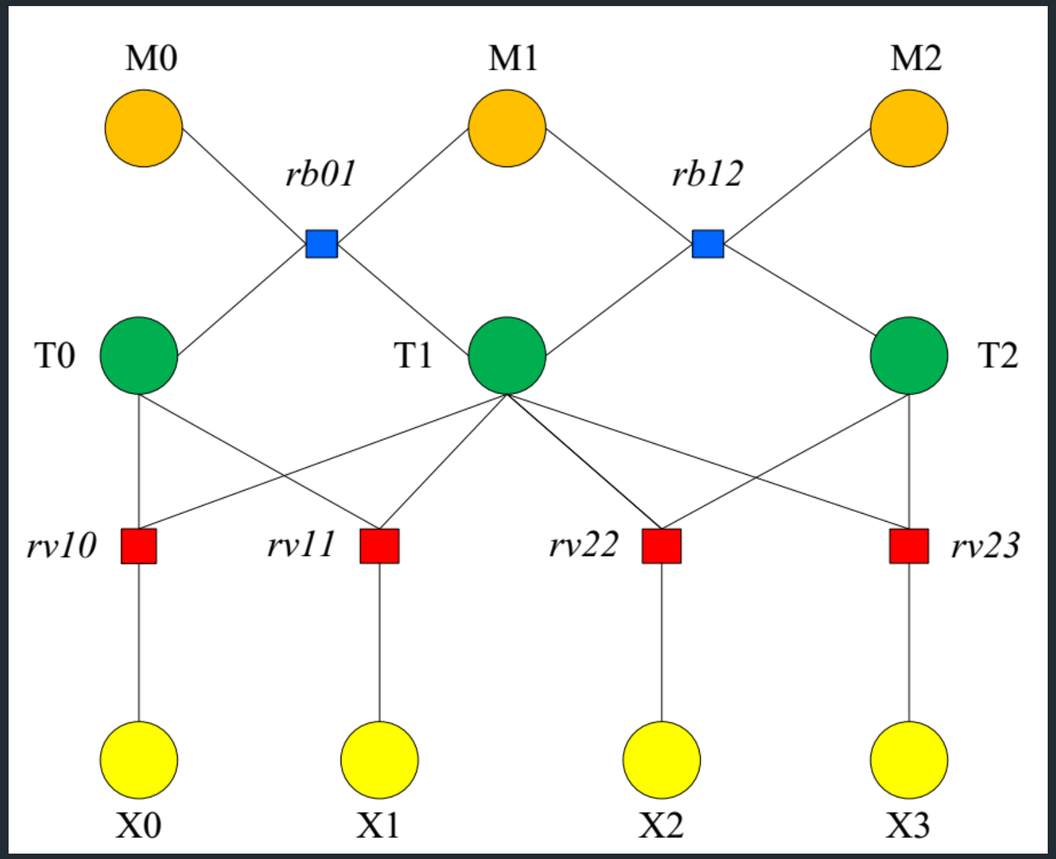
蓝色小块为IMU预积分引入的约束项，此项因子对Hession矩阵的影响如右图所示。
因子图与Hession矩阵的对应关系如下：





因子图——VIO的因子图表示

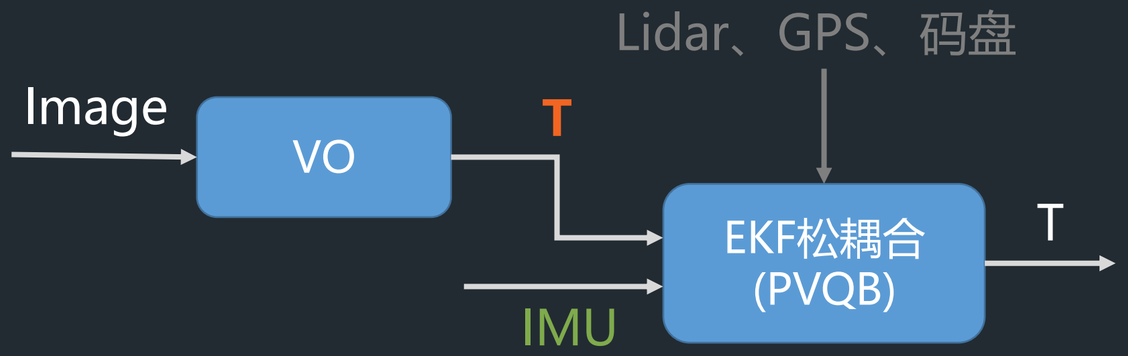


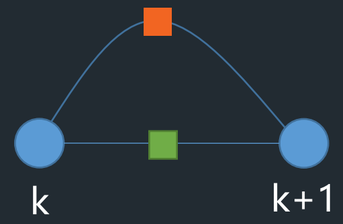


VIO分类：

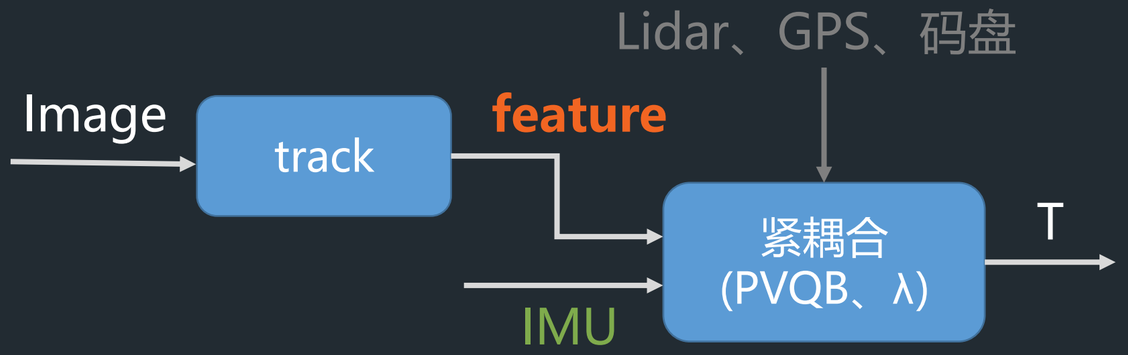
将视觉约束　　加入到联合优化是紧耦合
将视觉约束后的位姿加入到联合优化是松耦合

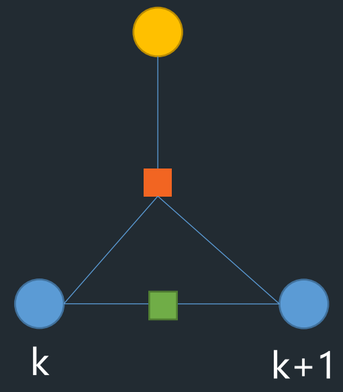
松耦合





紧耦合



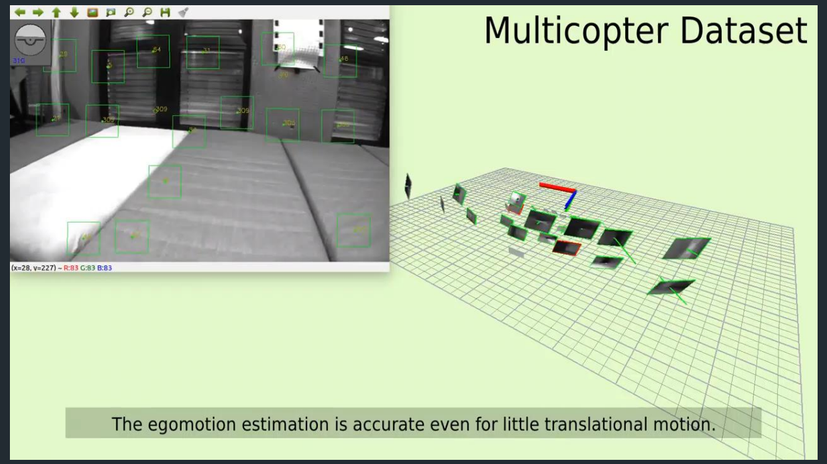


主流VIO

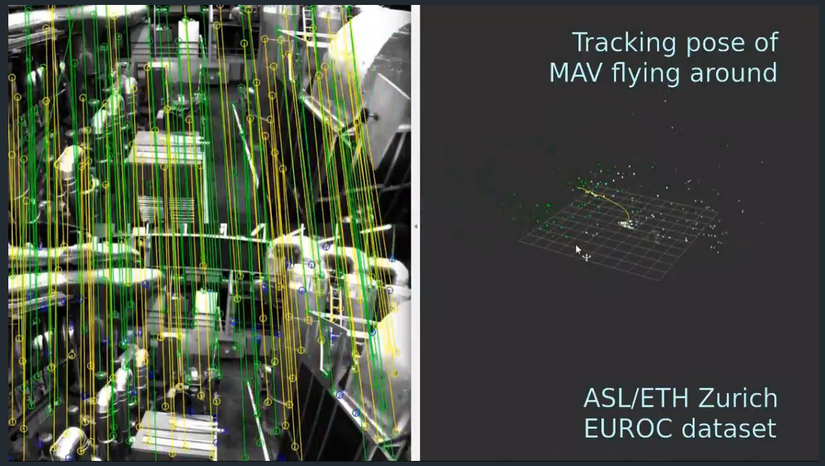
深蓝学院 shenlanxueyuan.com



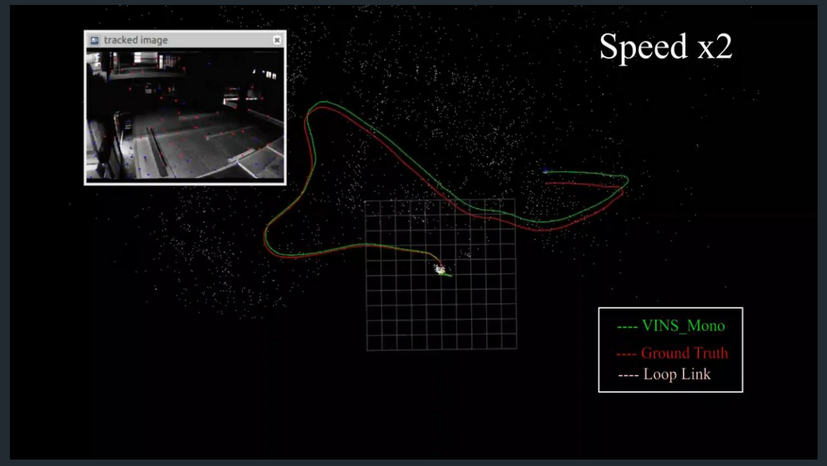
MSCKF



ROVIO



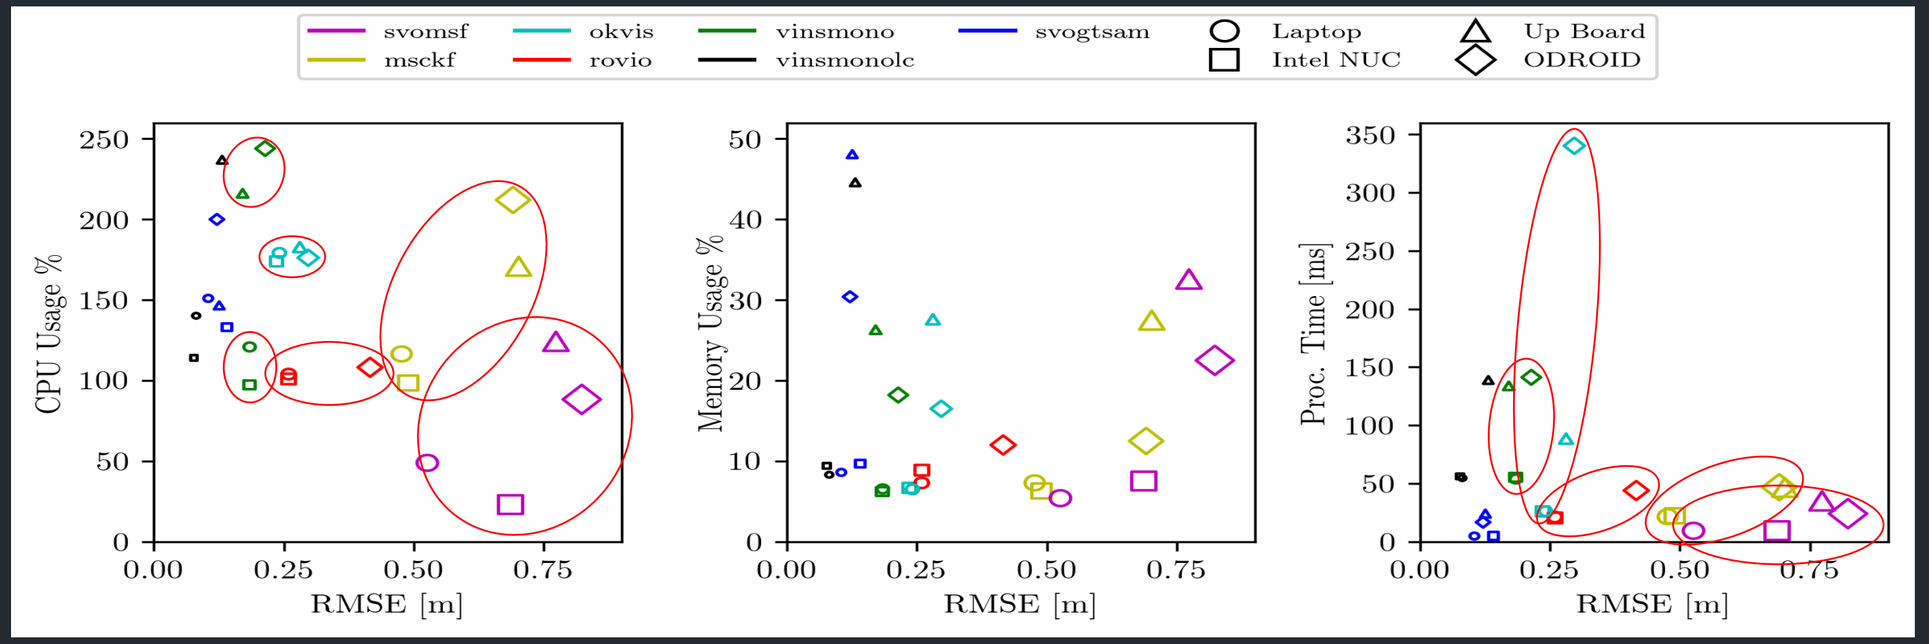
OKVIS



VINS-Mono

主流VIO

VIO框架	耦合方案	后端方案	前端	视觉误差	初始化	回环	精度	效率
MSF	松耦合	滤波EKF	\	\	\	\	最差1	最快5
MSCKF	紧耦合	滤波EKF	fast+光流	重投影	静止	无	较差2	较快4
ROVIO	紧耦合	滤波IEKF	fast+光度	光度	静止	无	一般3	较快4
OKVIS	紧耦合	优化	Harris+BRISK	重投影	静止	无	较好4	最慢1
VINS	紧耦合	优化	Harris+光流	重投影	动态	有	最好5	较慢2
VI-ORB	紧耦合	优化	orb	重投影	动态	有	\	\
ICE-BA	紧耦合	优化	Fast+光流	重投影	静止	无	\	\

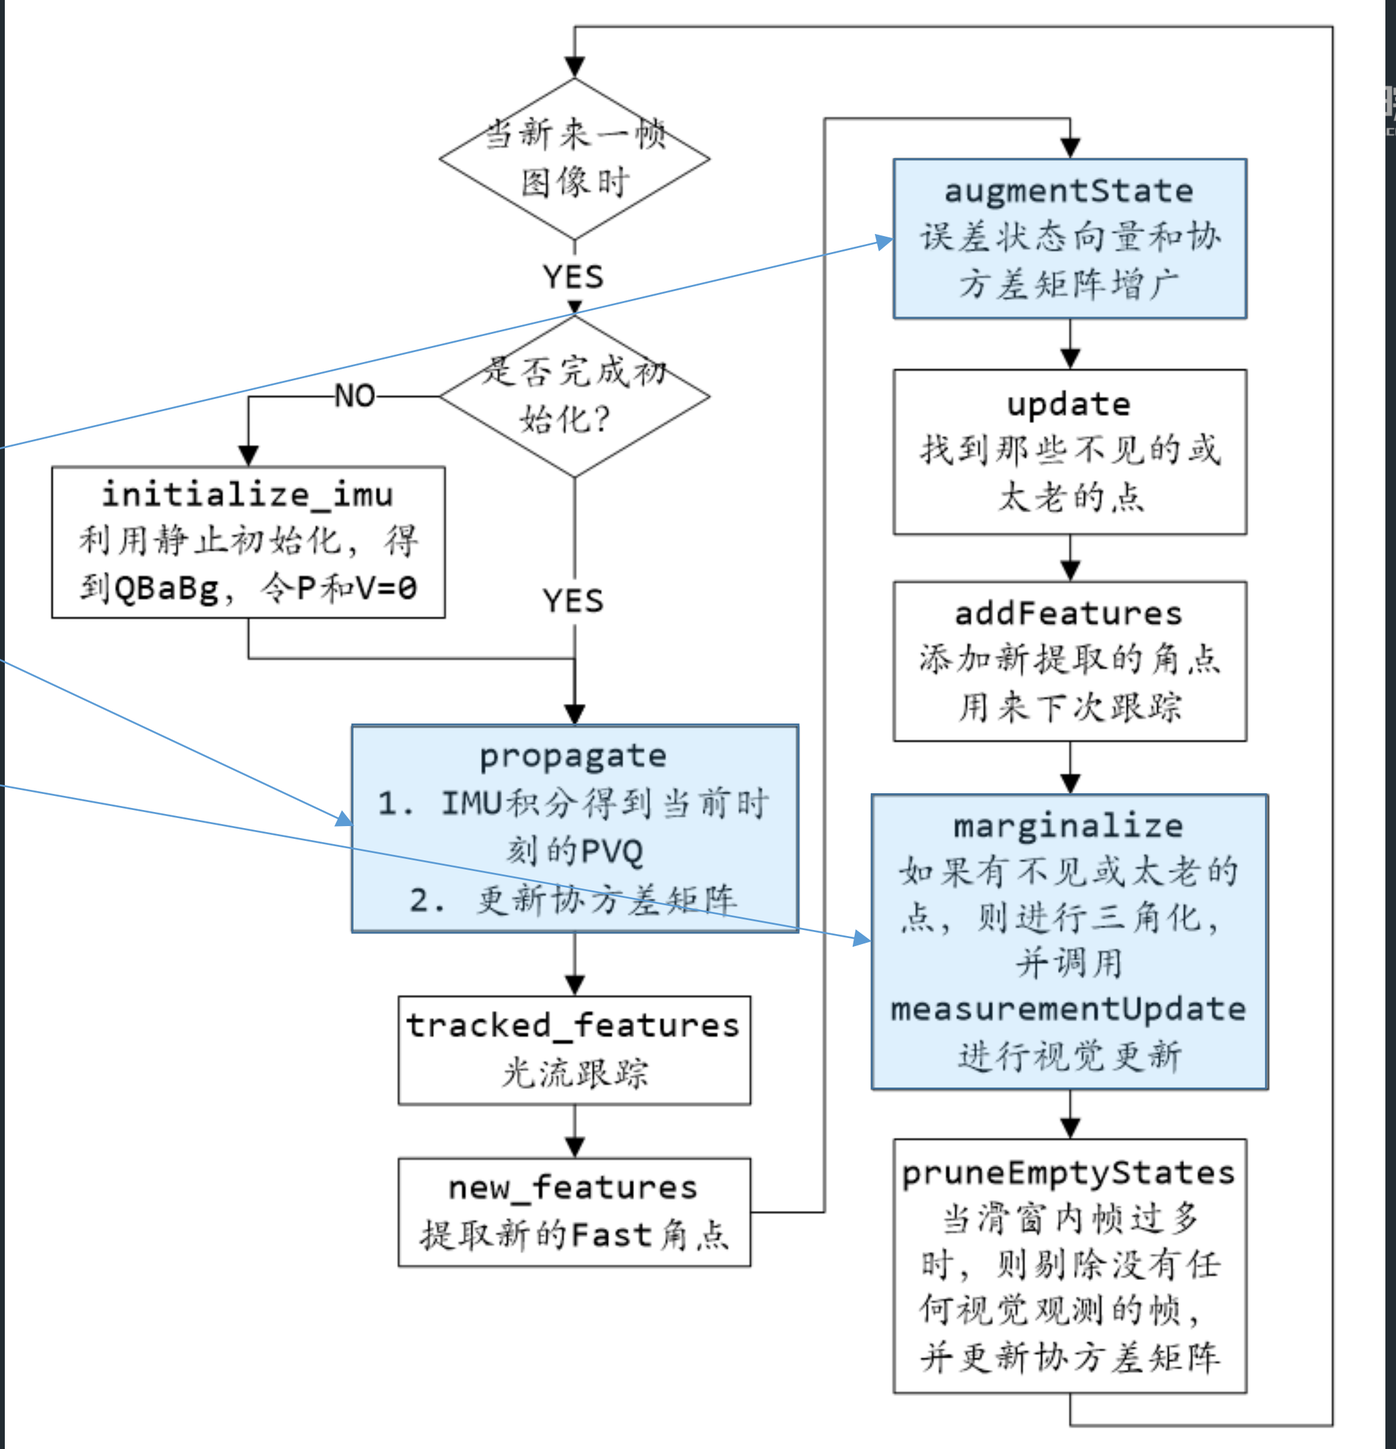


J. Delmerico. A Benchmark Comparison of Monocular Visual-Inertial Odometry Algorithms for Flying Robots. 2018. ICRA.

MSCKF

流程：

1. 初始化
2. IMU预测
3. 视觉跟踪
4. 视觉增广
5. 视觉更新—选老点或者看不见的点
6. 视觉更新—边缘化
7. 剔除老帧



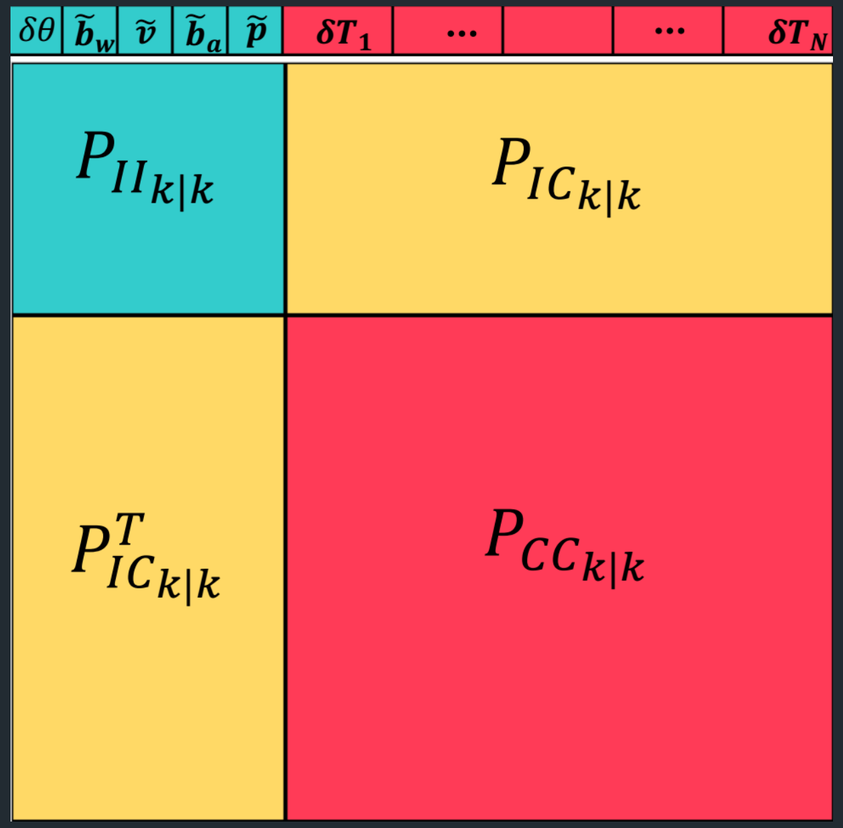
深蓝学院 shenlanxueyuan.com

MSCKF

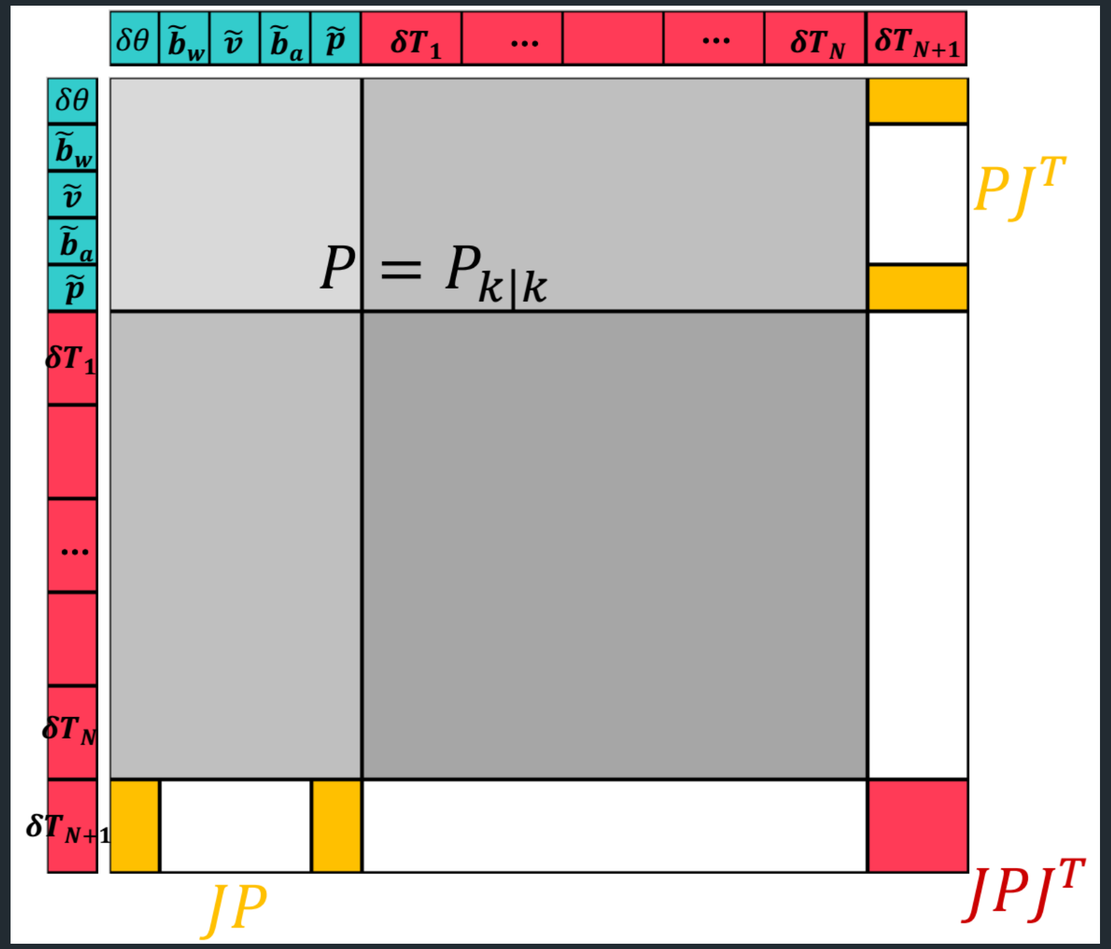
误差状态向量：

$$\tilde{X}_k^{(15+6N)\times 1} = \left[\tilde{X}_{IMU_k}\ \delta\theta_{C_1}\ {}^G\tilde{p}_{C_1}\ \cdots\ \delta\theta_{C_N}\ {}^G\tilde{p}_{C_N}\right]^T$$

$$\tilde{X}_{IMU_k}^{15\times 1} = \left[\delta\theta_I\ \tilde{b}_g\ {}^G\tilde{v}_I\ \tilde{b}_a\ {}^G\tilde{p}_I\right]^T$$



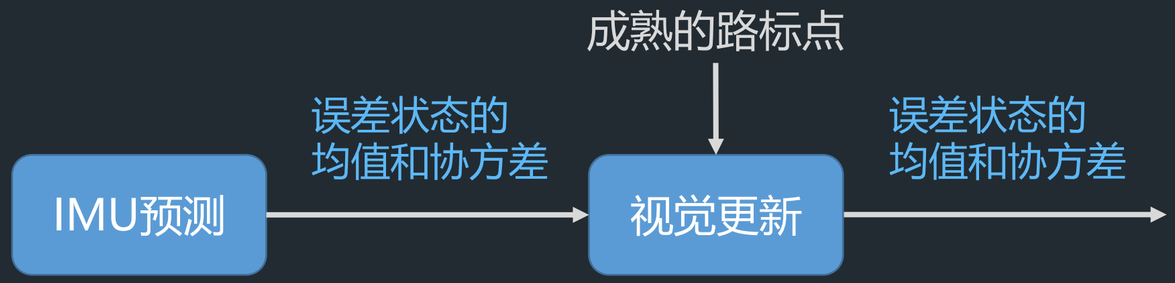
状态向量的协方差矩阵

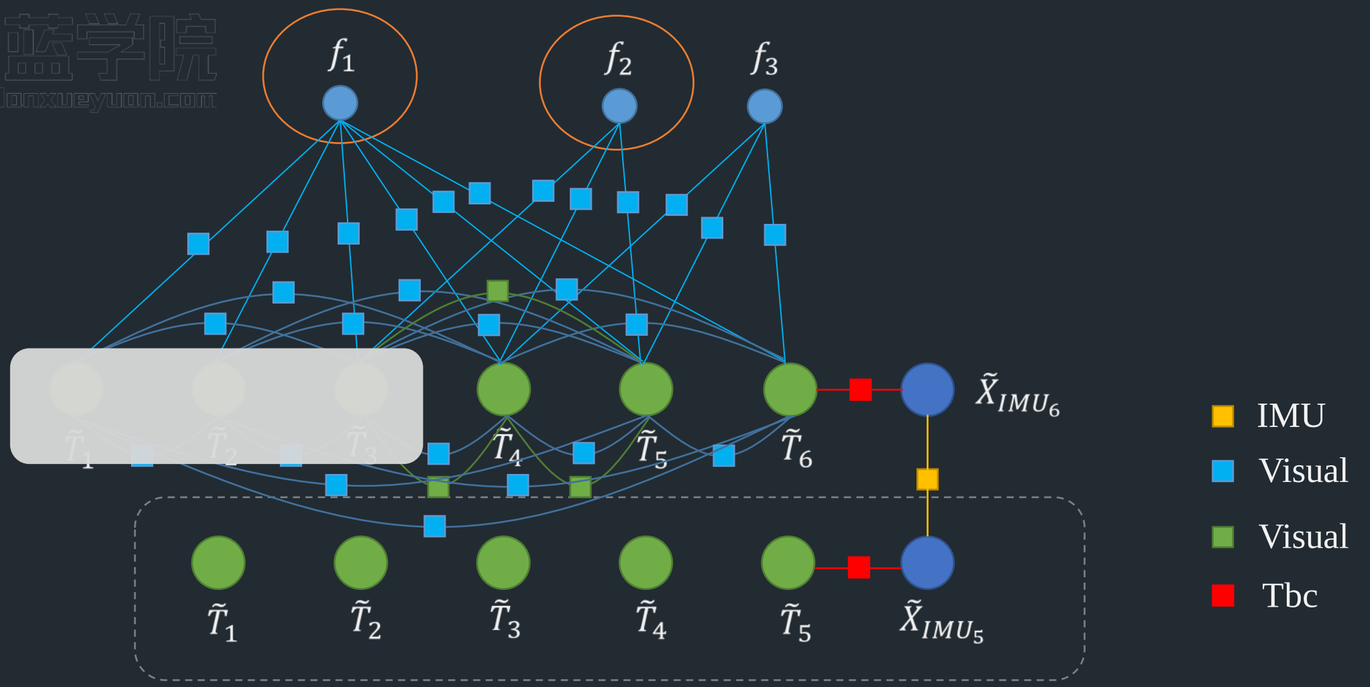


协方差矩阵的增广

深蓝学院 shenlanxueyuan.com

MSCKF



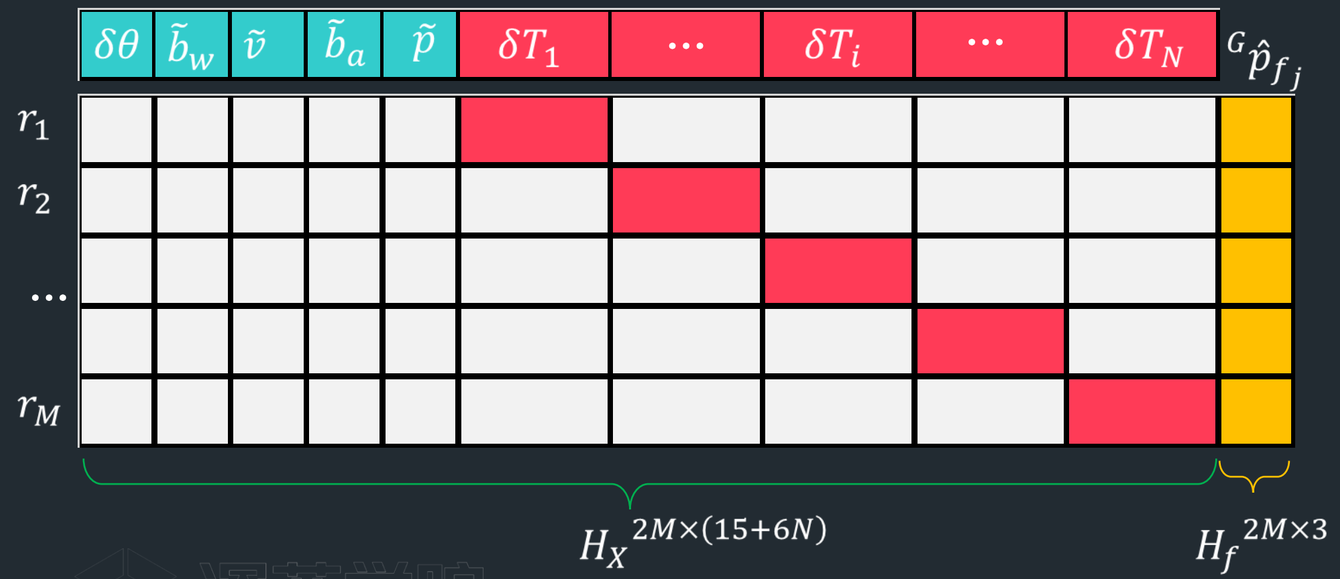


[1] A. I. Mourikis. A multi-state constraint kalman filter for vision-aided inertial navigation. Proc. ICRA, 2007.
[2] F. Gonzalez. Visual inertial odometry for mobile robotics. 2015.
[3] N. Trawny. Indirect kalman filter for 3D attitude estimation. 2005.
[4] L. Clement. The battle for filter supremacy: a comparative study of the multi-state constraint kalman filter and the sliding window filter. CVR. 2015.
[5] J. Sola. Quaternion kinematics for the error-state Kalman filter. 2017.

MSCKF

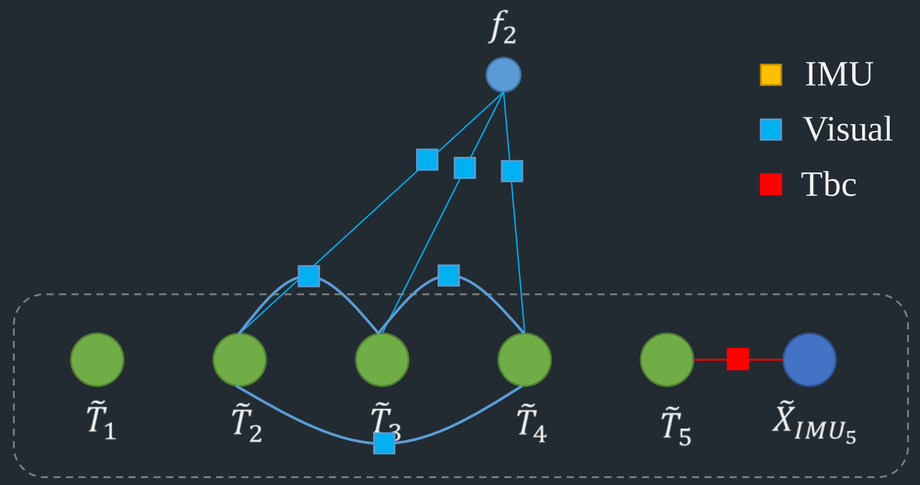
第 j 个路标点的所有视觉误差为：

$$r^{2M\times 1} \cong H_X^{2M\times(15+6N)} \tilde{X}^{(15+6N)\times 1} + H_f^{2M\times 3}\ {}^G\hat{p}_{f_j}^{3\times 1} + n^{2M\times 1}$$



将 r 投影到 H_f 的左零空间，相当于对路标点进行边缘化，将边缘化约束来优化共视帧。

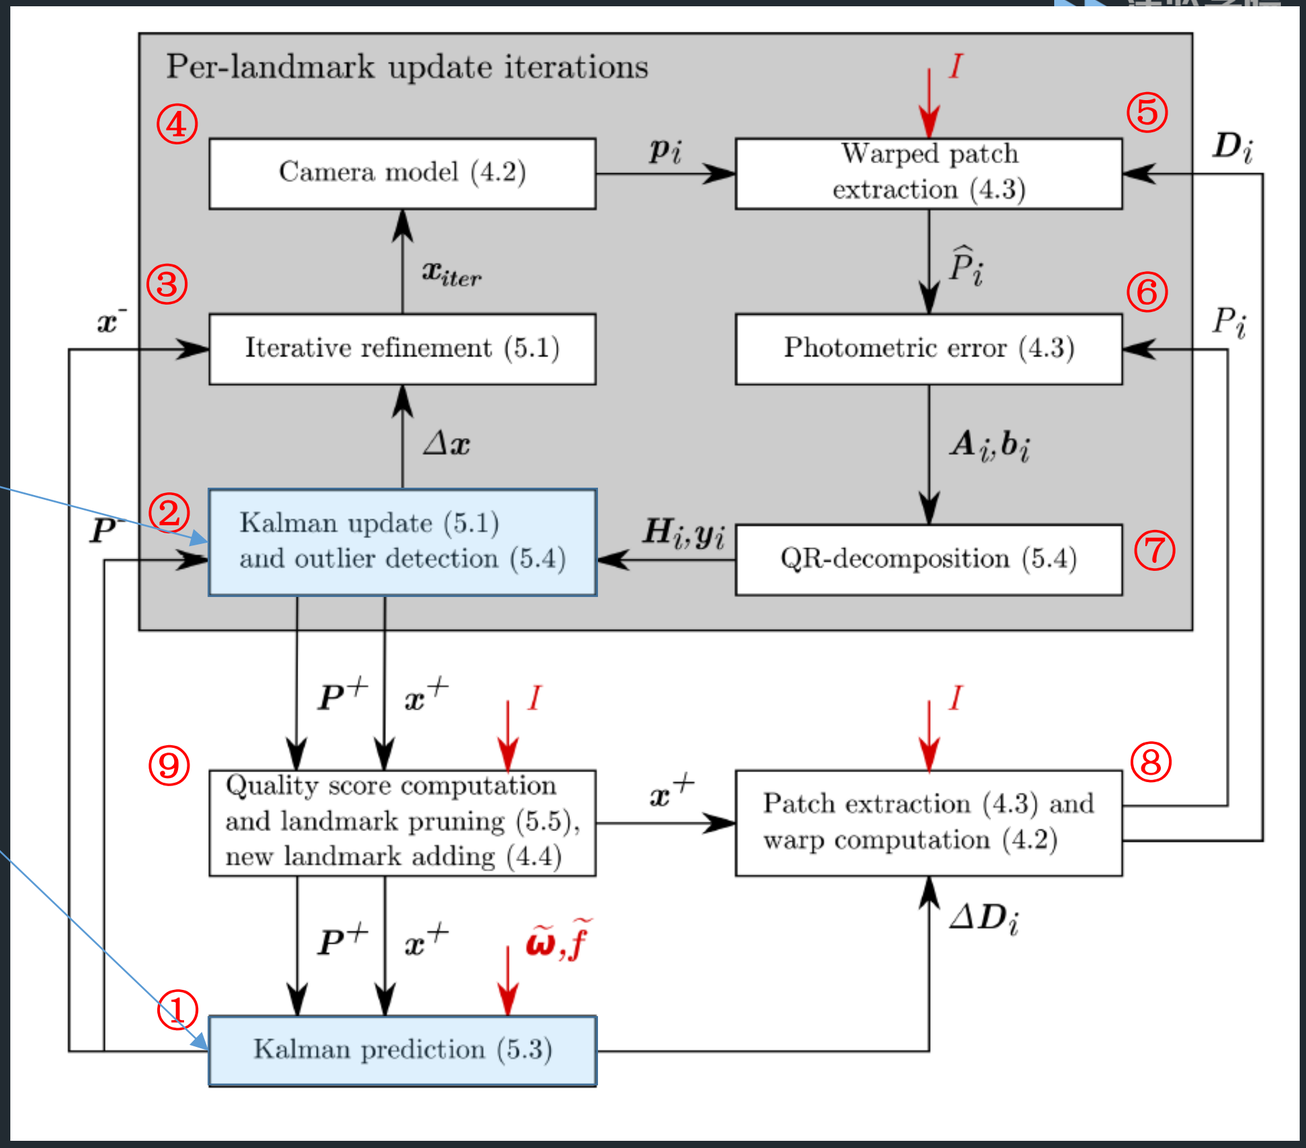
$$r_0^{(2M-3M_L)\times 1} = A^T r^{2M\times 1}$$
$$\cong \underbrace{A^T H_X^{2M\times(15+6N)}}_{H_0} \tilde{X}^{(15+6N)\times 1} + \underbrace{A^T n^{2M\times 1}}_{n_0}$$



ROVIO

流程：

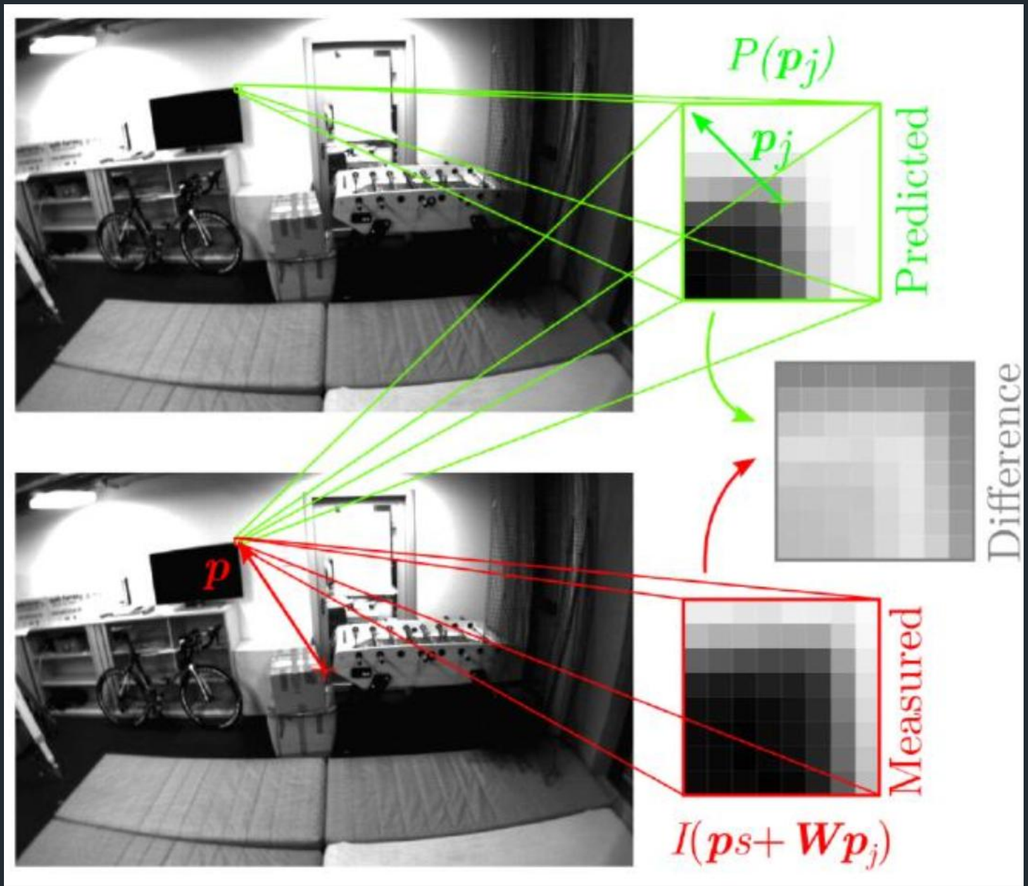
1. IMU预测
2. 视觉更新
3. IEKF
4. 相机模型
5. 像素坐标校正
6. 光度误差
7. QR分解
8. Patch提取及Warp计算
9. 路标点质量评价及维护



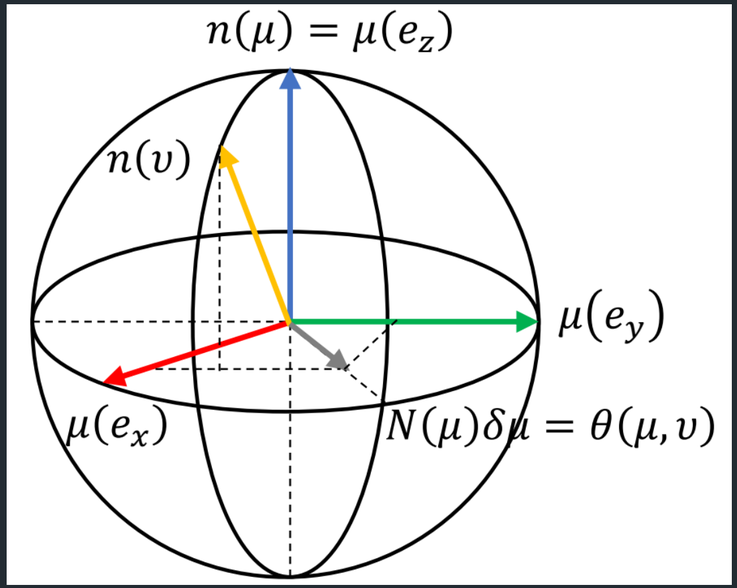
[1] M. Bloesch. IEKF-based visual-inertial odometry using direct photometric feedback. 2017.
[2] M. Bloesch. Robust visual inertial odometry using a direct ekf-based approach. 2015. IEEE.
[3] M. Bloesch. A primer on the differential calculus of 3d orientations. 2016. arXiv.
[4] C. Forster. On-manifold preintegration for real-time visual-inertial odometry. 2017.

深蓝学院 shenlanxueyuan.com

ROVIO



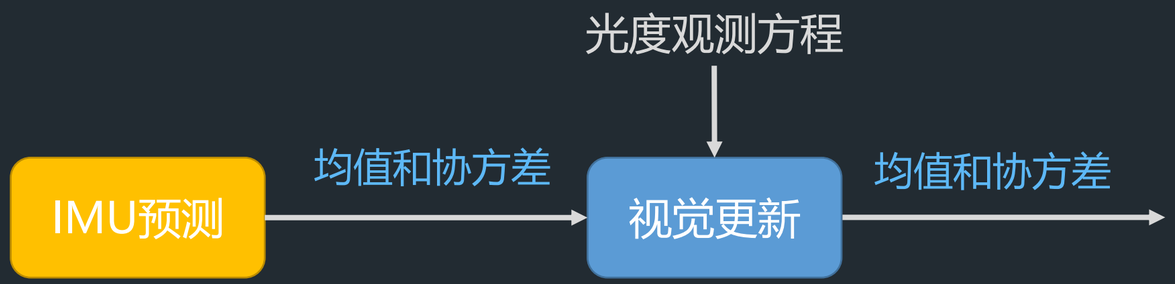
光度误差



ROVIO将路标点包含到状态向量中。又因将路标点表征在当前帧坐标系下，有范围限制，因此对其进行归一化得到无约束的状态量——方向向量 Bearing vector

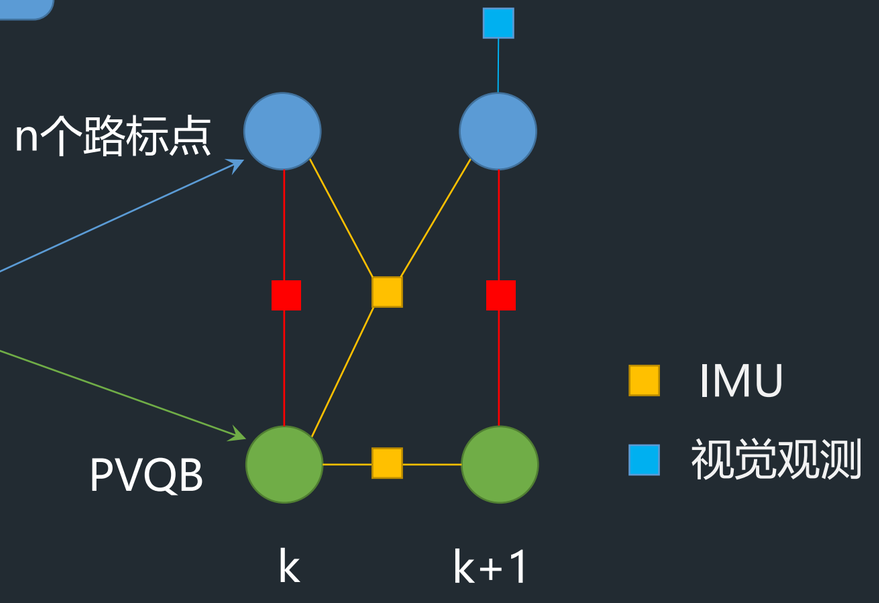
ROVIO

创新点：路标点用当前帧下的归一化相机系坐标Pc和逆深度表示，并作为状态向量进行预测和更新。参数化不同导致预测和更新的细节不同，但是总体还是EKF五大公式。又因Pc有边界约束，因此引入bearing vector来使得Pc平滑可导。



状态向量：当前帧的PVQB和路标点（μ、ρ）

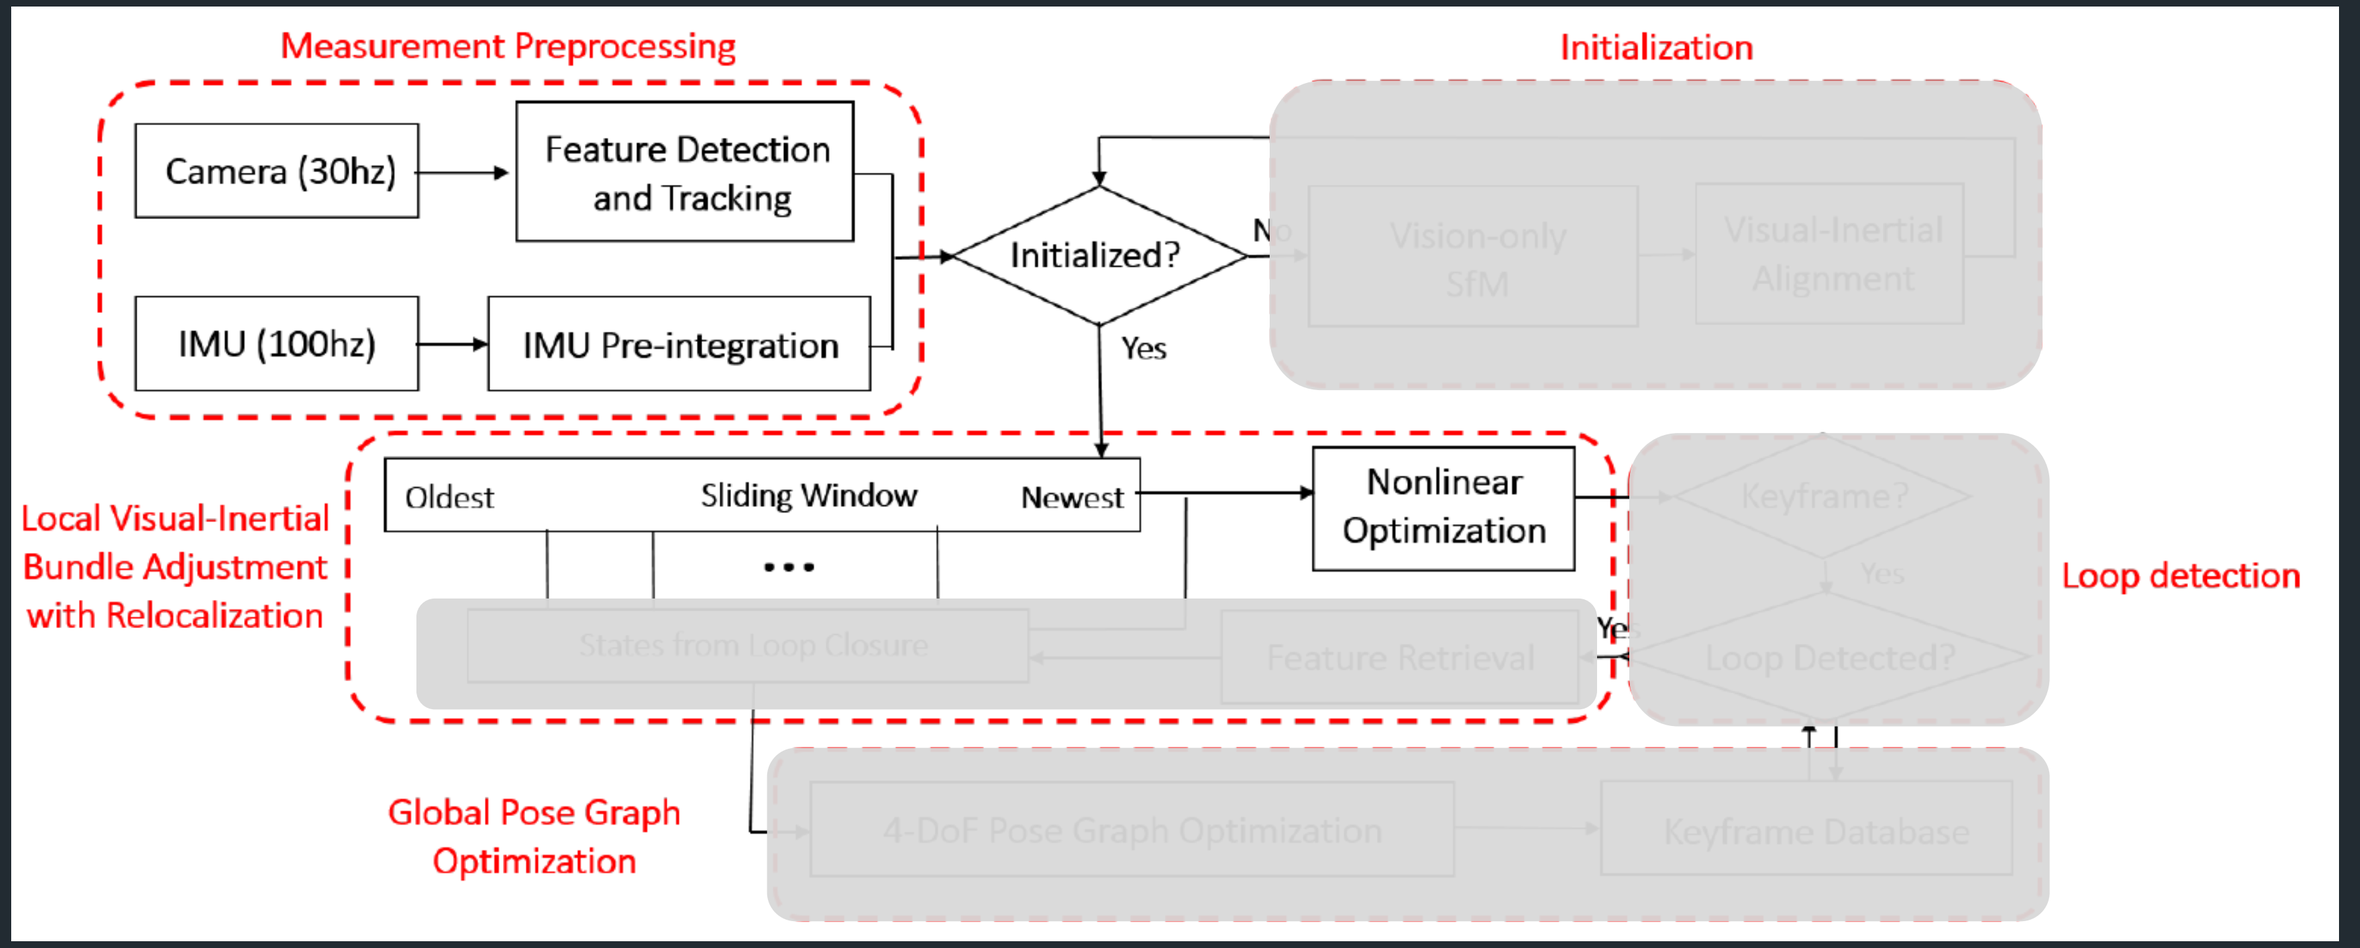
$$\chi^{(15+6+3N)\times 1} = \begin{pmatrix} p_{I\leftarrow B}, {}^{B}v_B, q_{I\leftarrow B}, {}^{B}b_f, {}^{B}b_w, p_{B\leftarrow C}, q_{C\leftarrow B}, \\ {}^{C}\mu_0, \cdots, {}^{C}\mu_{N-1}, \rho_0, \cdots, \rho_{N-1} \end{pmatrix}$$



ROVIO的因子图形式

深蓝学院 shenlanxueyuan.com

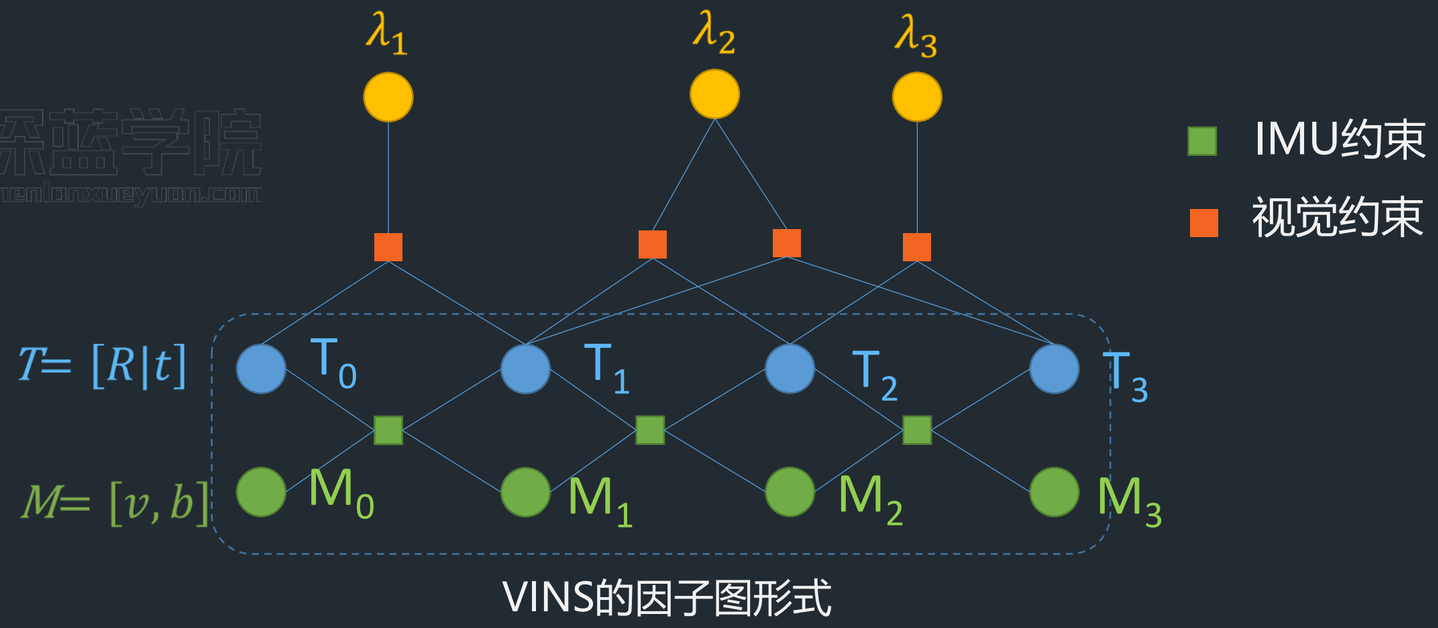
VINS


Measurement Preprocessing
Initialization
Camera (30hz)
Feature Detection and Tracking
IMU (100hz)
IMU Pre-integration
Initialized?
No
Yes
Vision-only SfM
Visual-Inertial Alignment
Local Visual-Inertial Bundle Adjustment with Relocalization
Oldest
Sliding Window
Newest
Nonlinear Optimization
States from Loop Closure
Feature Retrieval
Keyframe?
Yes
Loop Detected?
Loop detection
Global Pose Graph Optimization
4-DoF Pose Graph Optimization
Keyframe Database

VINS

优化向量包括滑动窗口内的n个相机状态PVQB、Camera到IMU的外参、m个3D点的逆深度：

$$X = [x_0, x_1, \cdots x_n, x_c^b, \lambda_0, \lambda_1, \cdots \lambda_m]$$



VINS的因子图形式

[1] T. Qin. VINS-Mono: A robust and versatile monocular visual-inertial state estimator. arXiv preprint arXiv: 1708.03852, 2017.

[2] N. Trawny. Indirect Kalman Filter for 3D Attitude Estimation. 2005.

[3] Sola. Quaternion kinematics for error-state kalman filter. 2017.

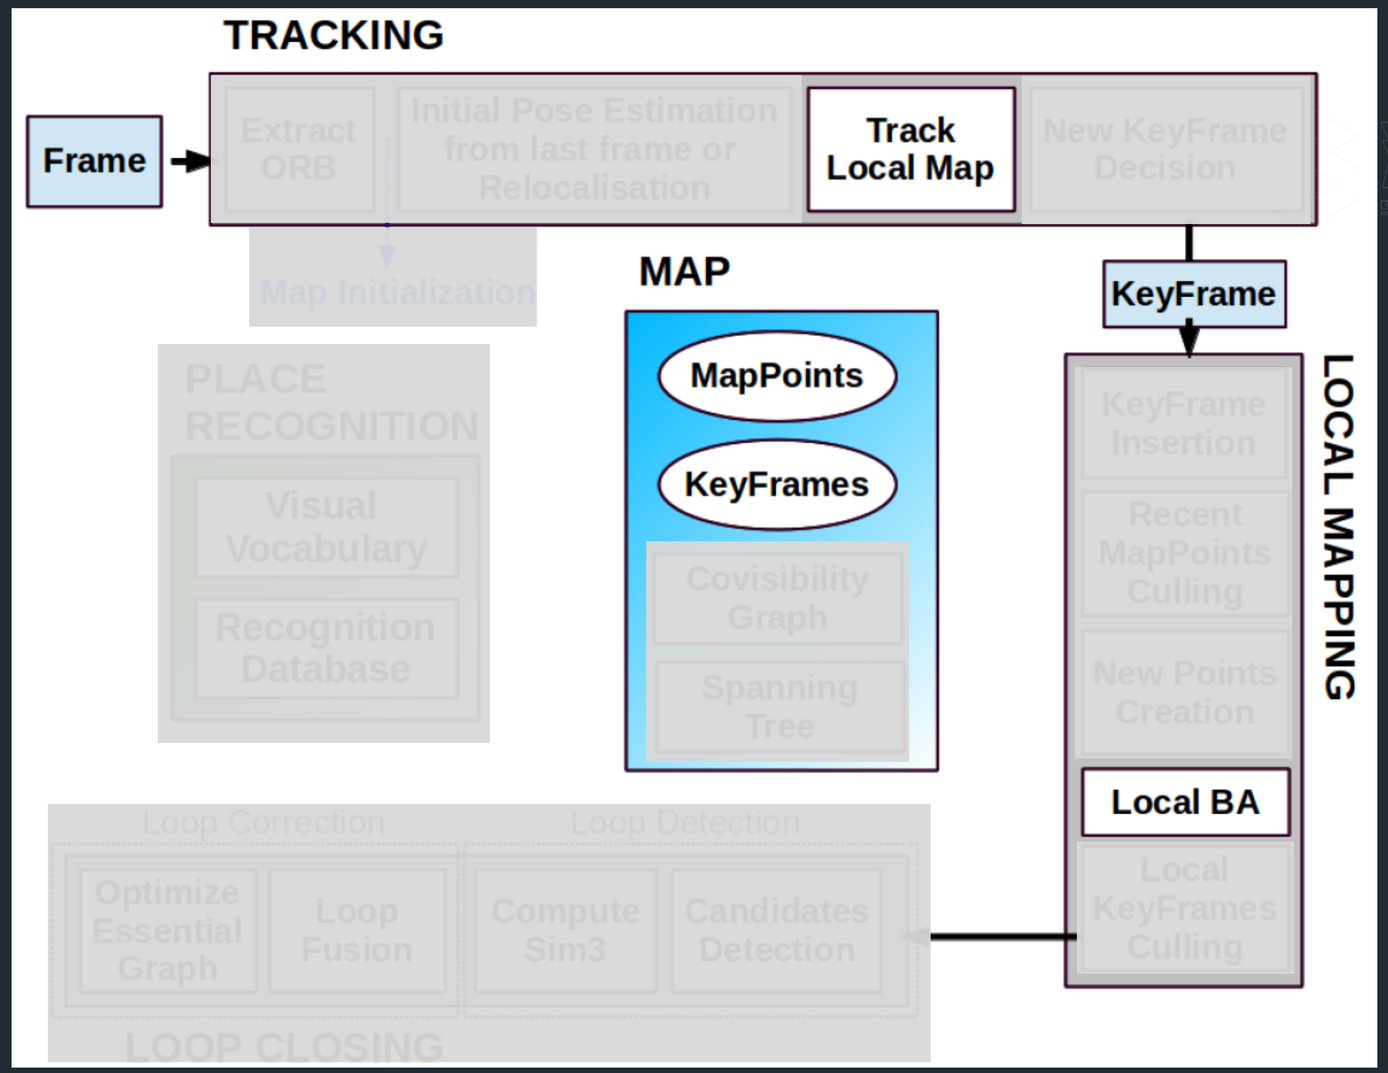
[4] K. Eckenhoff. Decoupled, Consistent Node Removal and Edge sparsification for graph-based SLAM. 2016.

[5] J. Engel. Direct Sparse Odometry. 2016.

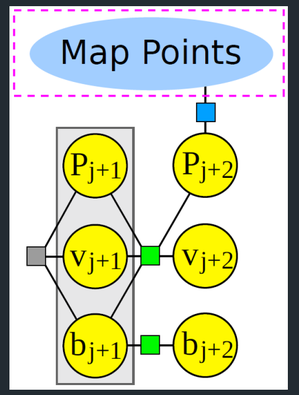
[6] Sliding Window Filter with Application to Planetary Landing. 2010.

[7] S. Leutenegger. Keyframe-Based Visual-Inertial SLAM Using Nonlinear Optimization. 2015.

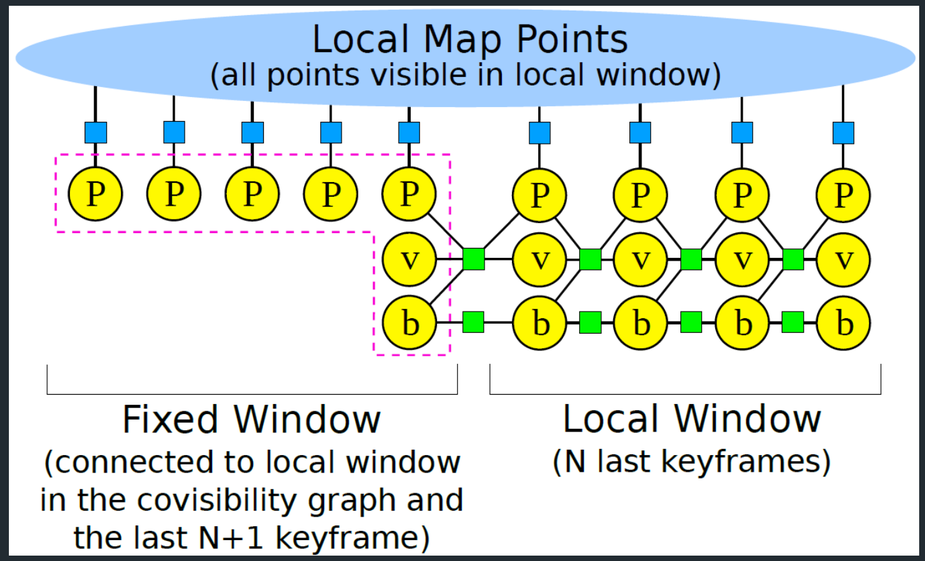
VI-ORB



Track Local Map：仅优化当前帧

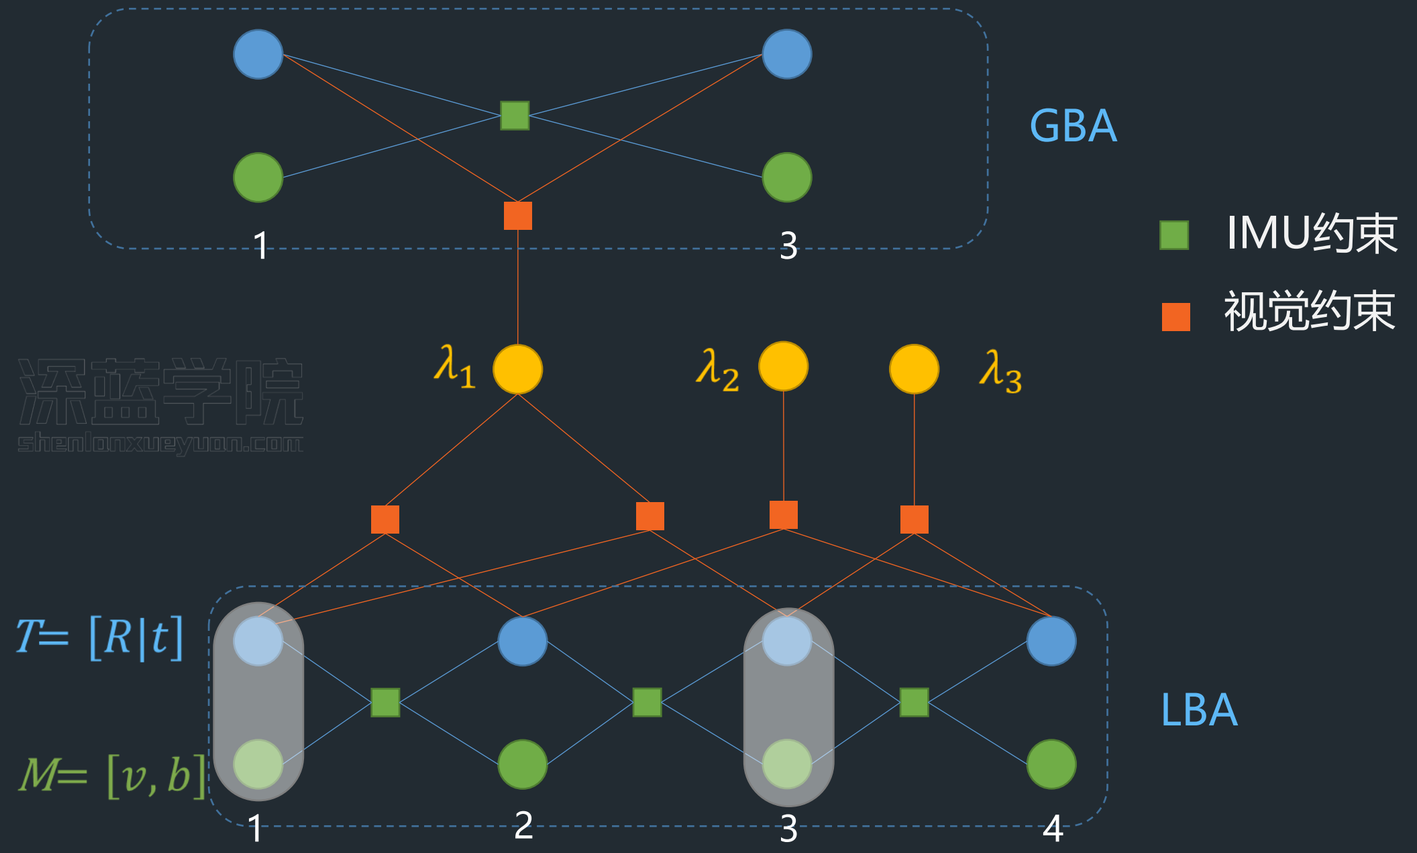


Local BA：优化滑窗内所有帧PVQB和路标点



ICE-BA

增量式BA，误差为IMU和视觉，LBA为滑窗优化，GBA为所有KF优化



ICE-BA的因子图形式

深蓝学院 shenlanxueyuan.com

[1] H. Liu. ICE-BA: Incremental, consisten and efficient bundle adjustment for visual-inertial slam. 2018. CVPR.

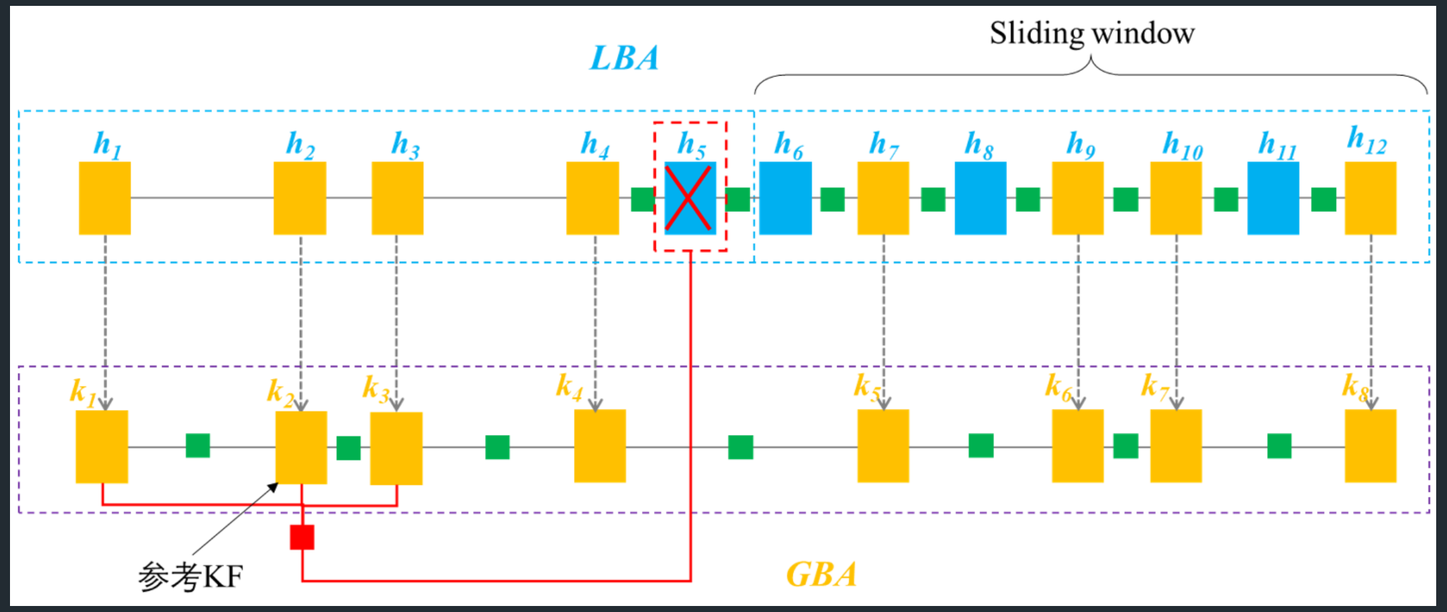
[2] H. Liu. Robust keyframe-based dense SLAM with an RGB-D camera. 2017.

ICE-BA的增量思想

ICE-BA认为在建立增量方程时，对之前已经算过的且不变的那些状态向量没必要重新线性化（线性化就是计算Jacobian），因为即使重新计算，得到的Jacobian也没什么变化。另外，也没必要对整体[H|b]矩阵进行消元，而是只对变化的进行更新。最后，只计算变化的路标点即可。对于没有变化的状态向量的临时值则一直保存下来，避免重新计算。

总结来说，在ICE-BA中更新Factor有三种情况：

1. 该Factor在本次迭代中没有变化，则不更新；
2. 该Factor是新Factor，则在原来基础上 +=新Factor。如新观察到一个新的路标点，则对此新路标点的观测约束就是一个新的Factor；
3. 该Factor已存在但需要更新，则先减去旧Factor，再加上新Factor。



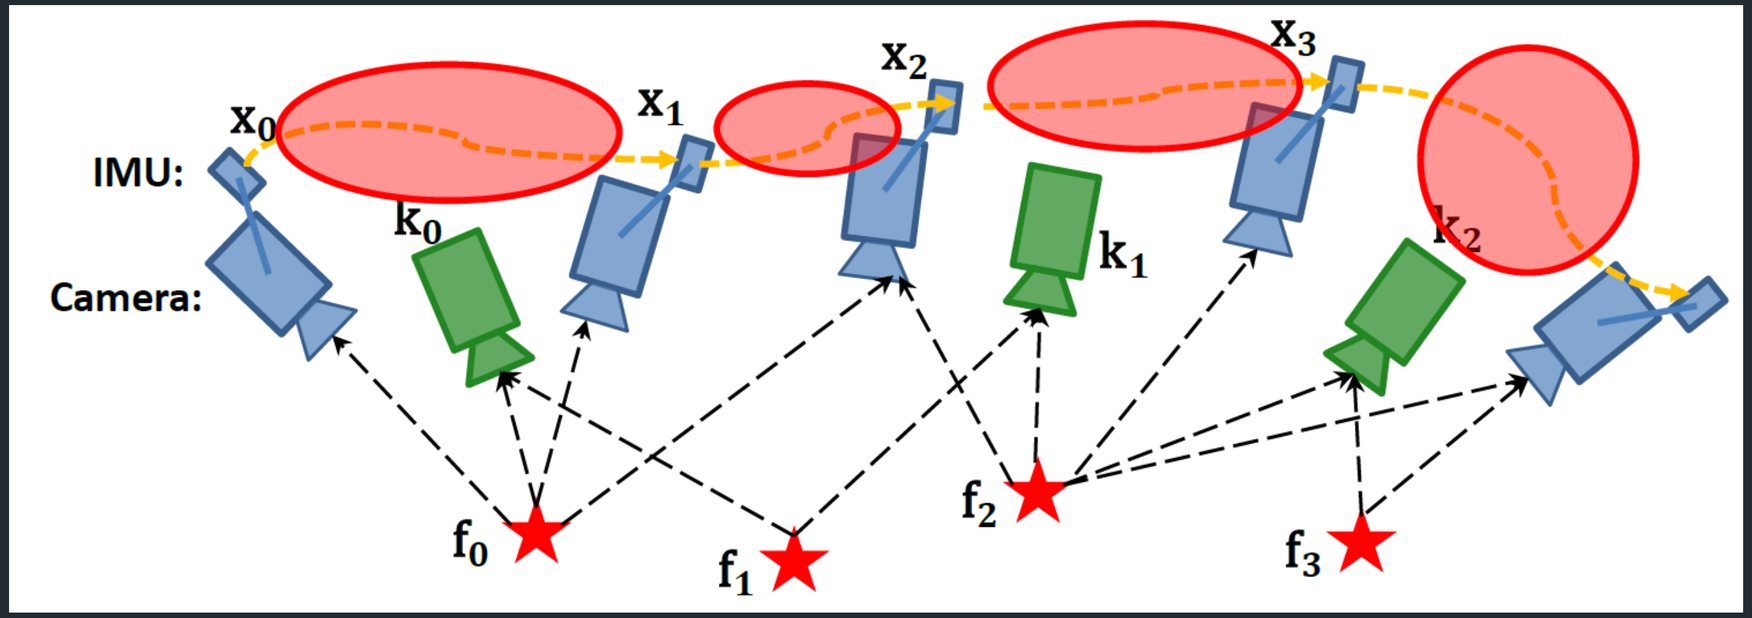
深蓝学院 shenlanxueyuan.com

[1] H. Liu. ICE-BA: Incremental, consisten and efficient bundle adjustment for visual-inertial slam. 2018. CVPR.
[2] H. Liu. Robust keyframe-based dense SLAM with an RGB-D camera. 2017.

深蓝学院
shenlanxueyuan.com

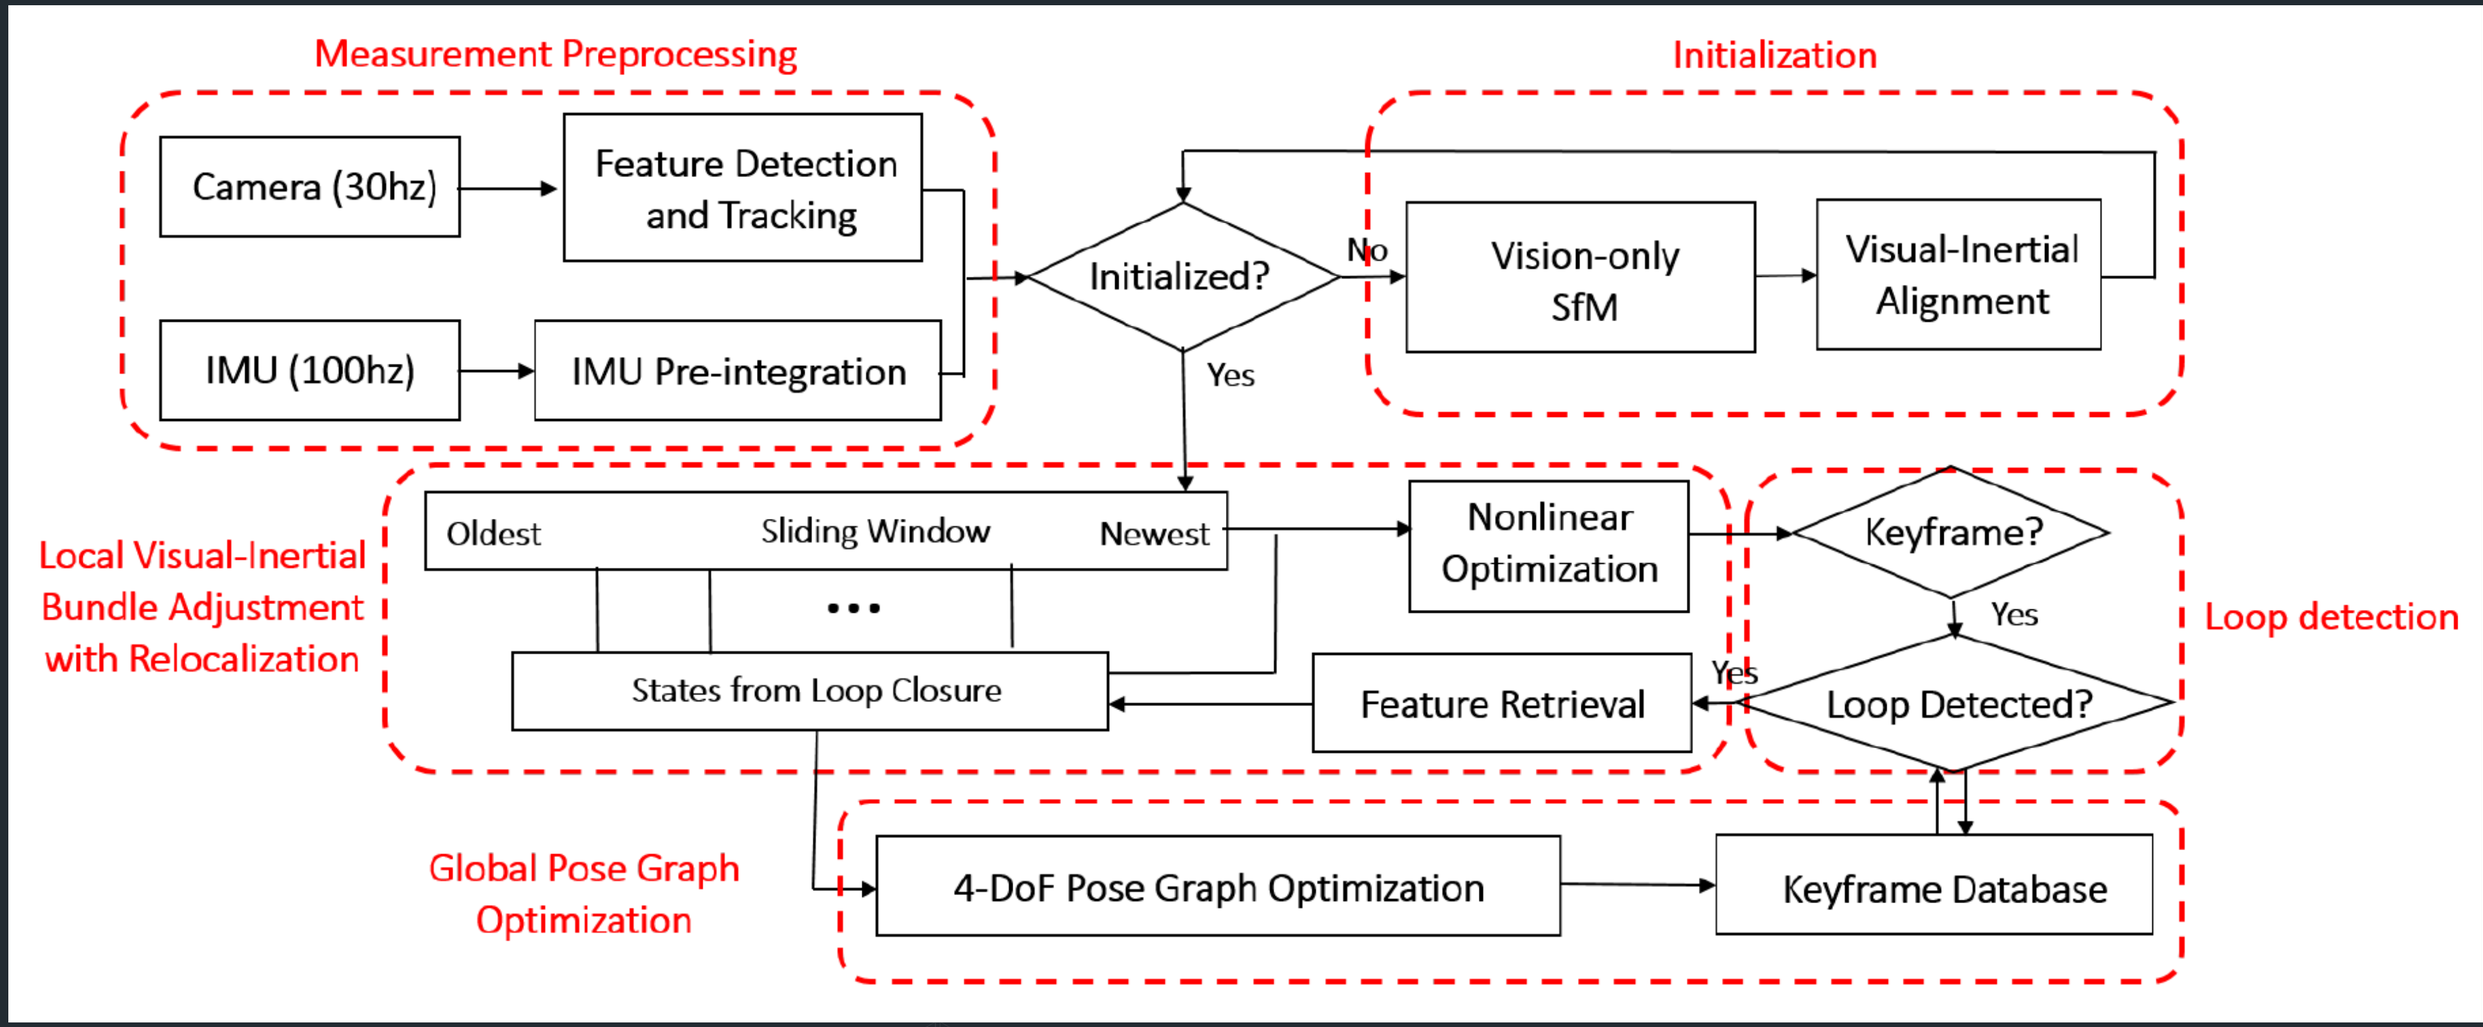
VINS论文推导及代码解析

VINS解析——框架



1. 黄色为IMU帧间约束（PVQBaBg 15×1）
2. 蓝色为视觉重投影误差约束（2×1）
3. 绿色为闭环帧，用来计算相对位姿，用于闭环优化时使用

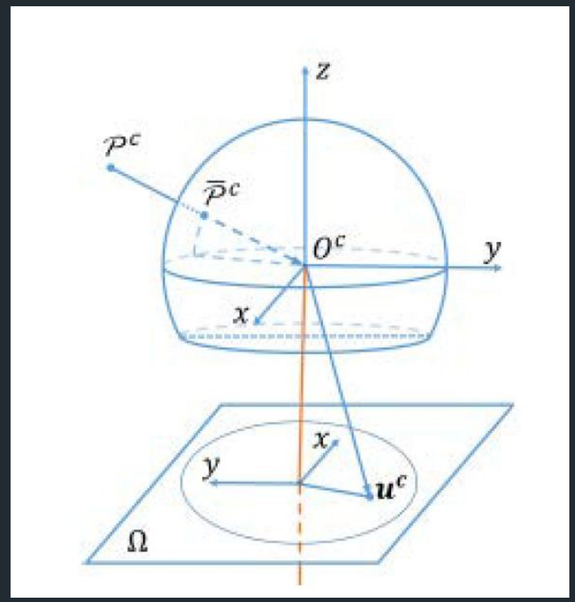
VINS解析——框架


Measurement Preprocessing
Camera (30hz)
Feature Detection and Tracking
IMU (100hz)
IMU Pre-integration
Initialized?
No
Yes
Initialization
Vision-only SfM
Visual-Inertial Alignment
Local Visual-Inertial Bundle Adjustment with Relocalization
Oldest
Sliding Window
Newest
States from Loop Closure
Nonlinear Optimization
Feature Retrieval
Keyframe?
Yes
Loop Detected?
Yes
Loop detection
Global Pose Graph Optimization
4-DoF Pose Graph Optimization
Keyframe Database

深蓝学院
shenlanxueyuan.com

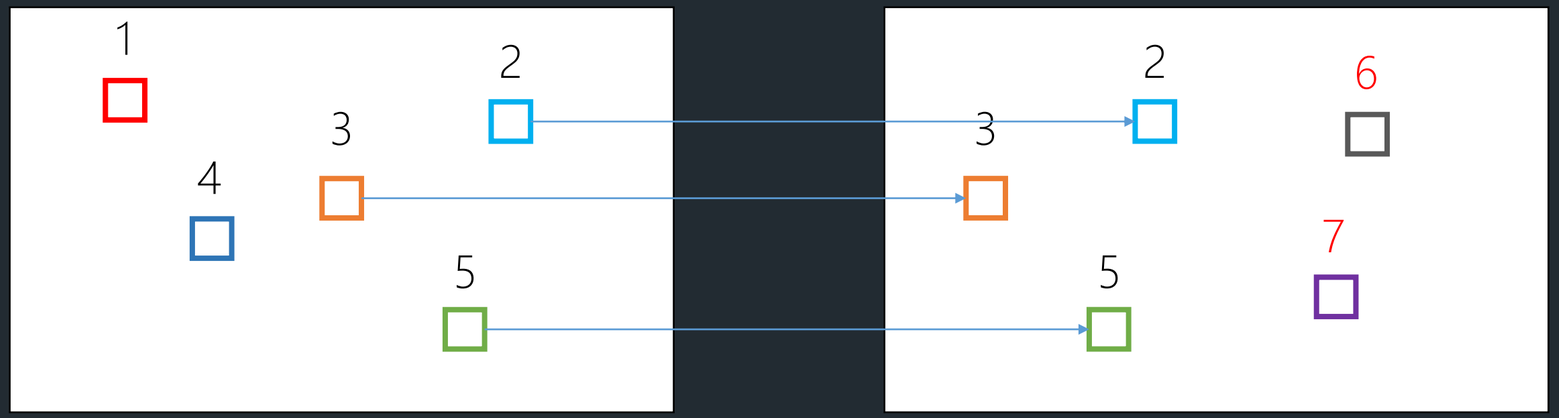
VINS解析——前端光流跟踪

1. cv::goodFeaturesToTrack 检测Harris 角点
2. cv::calcOpticalFlowPyrLK 跟踪相邻帧的角点
3. cv::findFundamentalMat 去除异常点
4. 统一的球面模型



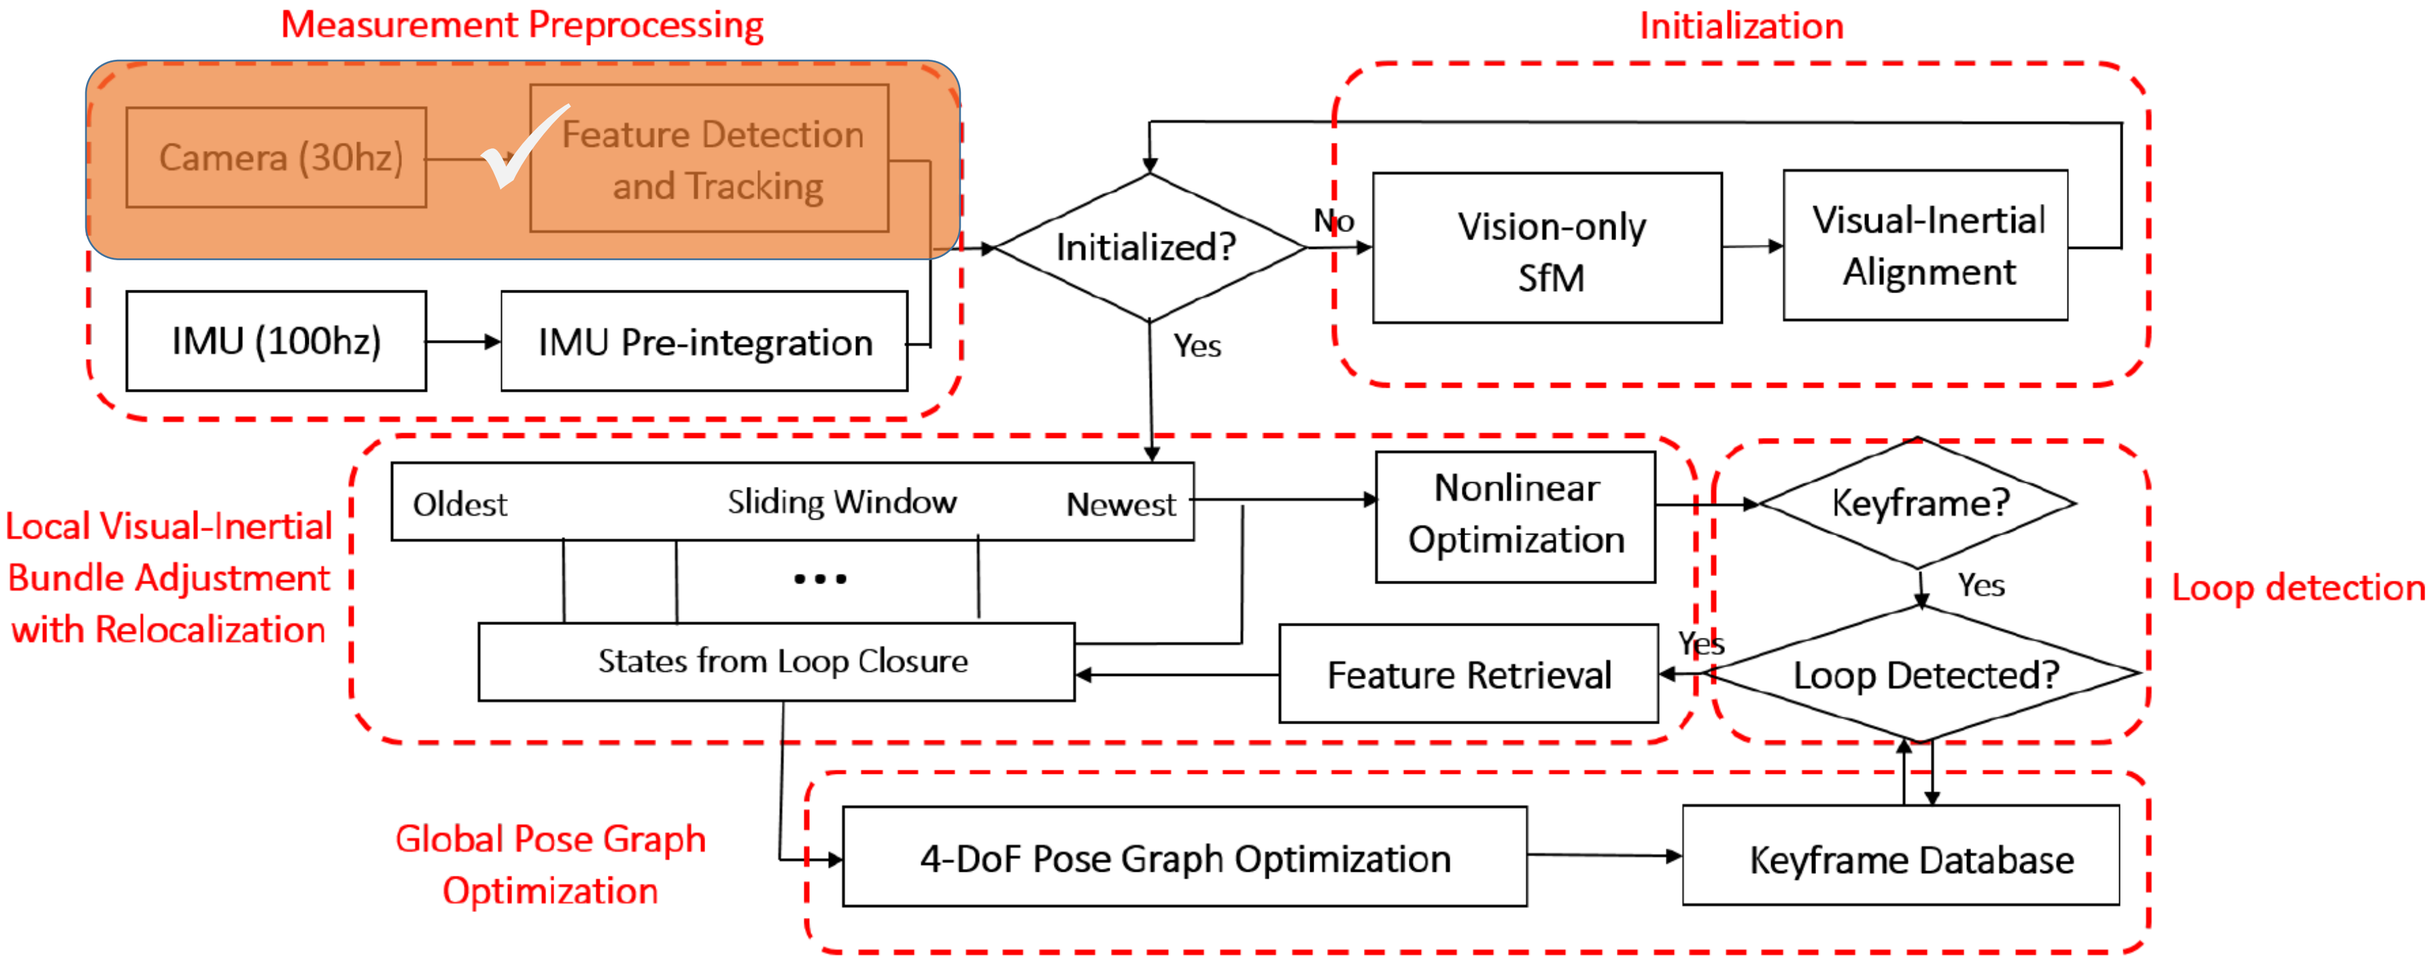
关键帧选择机制：

1. 平均视差大于某个阈值
2. 跟踪的特征点数量小于某个阈值



第一帧　　第二帧

深蓝学院 shenlanxueyuan.com



深蓝学院 shenlanxueyuan.com

VINS解析——IMU预积分

深蓝学院 shenlanxueyuan.com

二、IMU 预积分.....

2.1 当前时刻 PVQ 的连续形式.....

2.2 当前时刻 PVQ 的中值法离散形式.....

2.3 两帧之间 PVQ 增量的连续形式.....

2.4 两帧之间 PVQ 增量的欧拉法离散形式.....

2.5 两帧之间 PVQ 增量的中值法离散形式.....

2.6 连续形式下 PVQ 增量的误差、协方差及 Jacobian..

2.7 离散形式的 PVQ 增量误差分析.....

2.8 离散形式的 PVQ 增量误差的 Jacobian 和协方差....

积分出每帧的位姿，为视觉提供初始值

进行IMU预积分
欧拉法->论文
中值法->代码

构建IMU误差、协方差和Jacobian

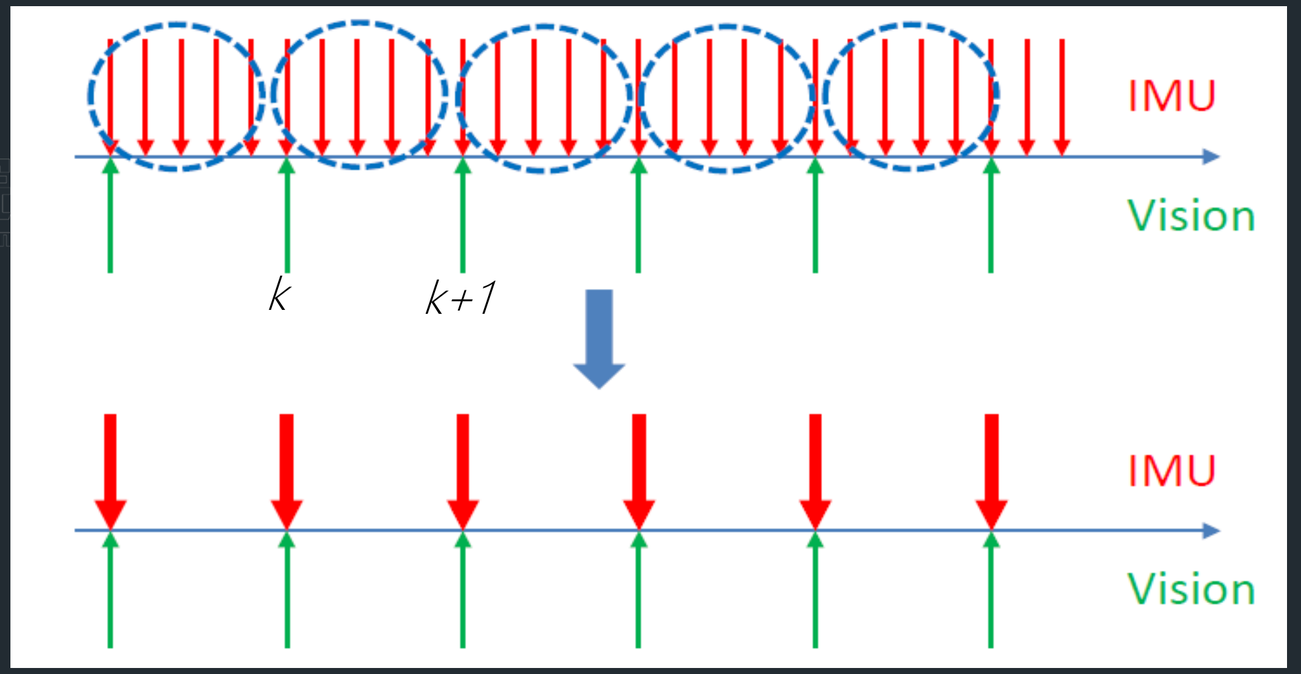
VINS解析——IMU预积分

1. 当前帧的位置、速度、旋转：

$$p_{b_{k+1}}^{w} = p_{b_k}^{w} + v_{b_k}^{w}\Delta t_k + \iint_{t\in[k,k+1]}\left[R_t^w\left(\hat{a}_t - b_{a_t}\right) - g^w\right]dt^2$$

$$v_{b_{k+1}}^{w} = v_{b_k}^{w} + \int_{t\in[k,k+1]}\left[R_t^w\left(\hat{a}_t - b_{a_t}\right) - g^w\right]dt$$

$$q_{b_{k+1}}^{w} = q_{b_k}^{w} \otimes \int_{t\in[k,k+1]}\frac{1}{2}\Omega\left(\hat{\omega}_t - b_{\omega_t}\right)q_t^{b_k}dt$$



深蓝学院 shenlanxueyuan.com

深蓝学院 shenlanxueyuan.com

2. 相邻两帧之间的位置、速度、旋转的变化量：

$$R_w^{b_k} p_{b_{k+1}}^w = R_w^{b_k}\left(p_{b_k}^w + v_{b_k}^w \Delta t_k - \frac{1}{2} g^w \Delta t_k^2\right) + \alpha_{b_{k+1}}^{b_k}$$

$$R_w^{b_k} v_{b_{k+1}}^w = R_w^{b_k}\left(v_{b_k}^w - g^w \Delta t_k\right) + \beta_{b_{k+1}}^{b_k}$$

$$q_w^{b_k} \otimes q_{b_{k+1}}^w = \gamma_{b_{k+1}}^{b_k}$$

深蓝学院 shenlanxueyuan.com

$$\alpha_{b_{k+1}}^{b_k} = \iint_{t\in[k,k+1]} \left[R_t^{b_k}\left(\hat{a}_t - b_{a_t}\right)\right] dt^2$$

$$\beta_{b_{k+1}}^{b_k} = \int_{t\in[k,k+1]} \left[R_t^{b_k}\left(\hat{a}_t - b_{a_t}\right)\right] dt$$

$$\gamma_{b_{k+1}}^{b_k} = \int_{t\in[k,k+1]} \frac{1}{2}\Omega\left(\hat{\omega}_t - b_{\omega_t}\right)\gamma_t^{b_k} dt$$

$$\alpha_{b_{k+1}}^{b_k} \approx \hat{\alpha}_{b_{k+1}}^{b_k} + J_{b_a}^{\alpha}\delta b_a + J_{b_\omega}^{\alpha}\delta b_\omega$$

$$\beta_{b_{k+1}}^{b_k} \approx \hat{\beta}_{b_{k+1}}^{b_k} + J_{b_a}^{\beta}\delta b_a + J_{b_\omega}^{\beta}\delta b_\omega$$

$$\gamma_{b_{k+1}}^{b_k} \approx \hat{\gamma}_{b_{k+1}}^{b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} J_{b_\omega}^{\gamma}\delta b_\omega \end{bmatrix}$$

3. IMU预积分的误差分析

$$\begin{bmatrix} \delta\dot{\alpha}_t^{b_k} \\ \delta\dot{\beta}_t^{b_k} \\ \delta\dot{\theta}_t^{b_k} \\ \delta\dot{b}_{a_t} \\ \delta\dot{b}_{w_t} \end{bmatrix} = \begin{bmatrix} 0 & I & 0 & 0 & 0 \\ 0 & 0 & -R_t^{b_k}(\hat{a}_t - b_{a_t})^\wedge & -R_t^{b_k} & 0 \\ 0 & 0 & -(\hat{\omega}_t - b_{\omega_t})^\wedge & 0 & -I \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \delta\alpha_t^{b_k} \\ \delta\beta_t^{b_k} \\ \delta\theta_t^{b_k} \\ \delta b_{a_t} \\ \delta b_{w_t} \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 & 0 \\ -R_t^{b_k} & 0 & 0 & 0 \\ 0 & -I & 0 & 0 \\ 0 & 0 & I & 0 \\ 0 & 0 & 0 & I \end{bmatrix} \begin{bmatrix} n_a \\ n_w \\ n_{b_a} \\ n_{b_w} \end{bmatrix} = F_t \delta z_t^{b_k} + G_t n_t$$

根据IMU的动力学方程可推导出在任意t时刻的预积分误差的传递方程

相邻时刻的误差传递方程：

$$\delta z_{t+\delta t}^{b_k} = (\mathrm{I} + F_t \delta t)\delta z_t^{b_k} + (G_t \delta t) n_t$$

深蓝学院 shenlanxueyuan.com

4. IMU预积分误差的协方差和Jacobian计算

$$P_{t+\delta t}^{b_k} = (\mathrm{I} + F_t \delta t) P_t^{b_k} (\mathrm{I} + F_t \delta t)^T + (G_t \delta t) Q (G_t \delta t)^T$$

$$J_{t+\delta t} = (\mathrm{I} + F_t \delta t) J_t$$

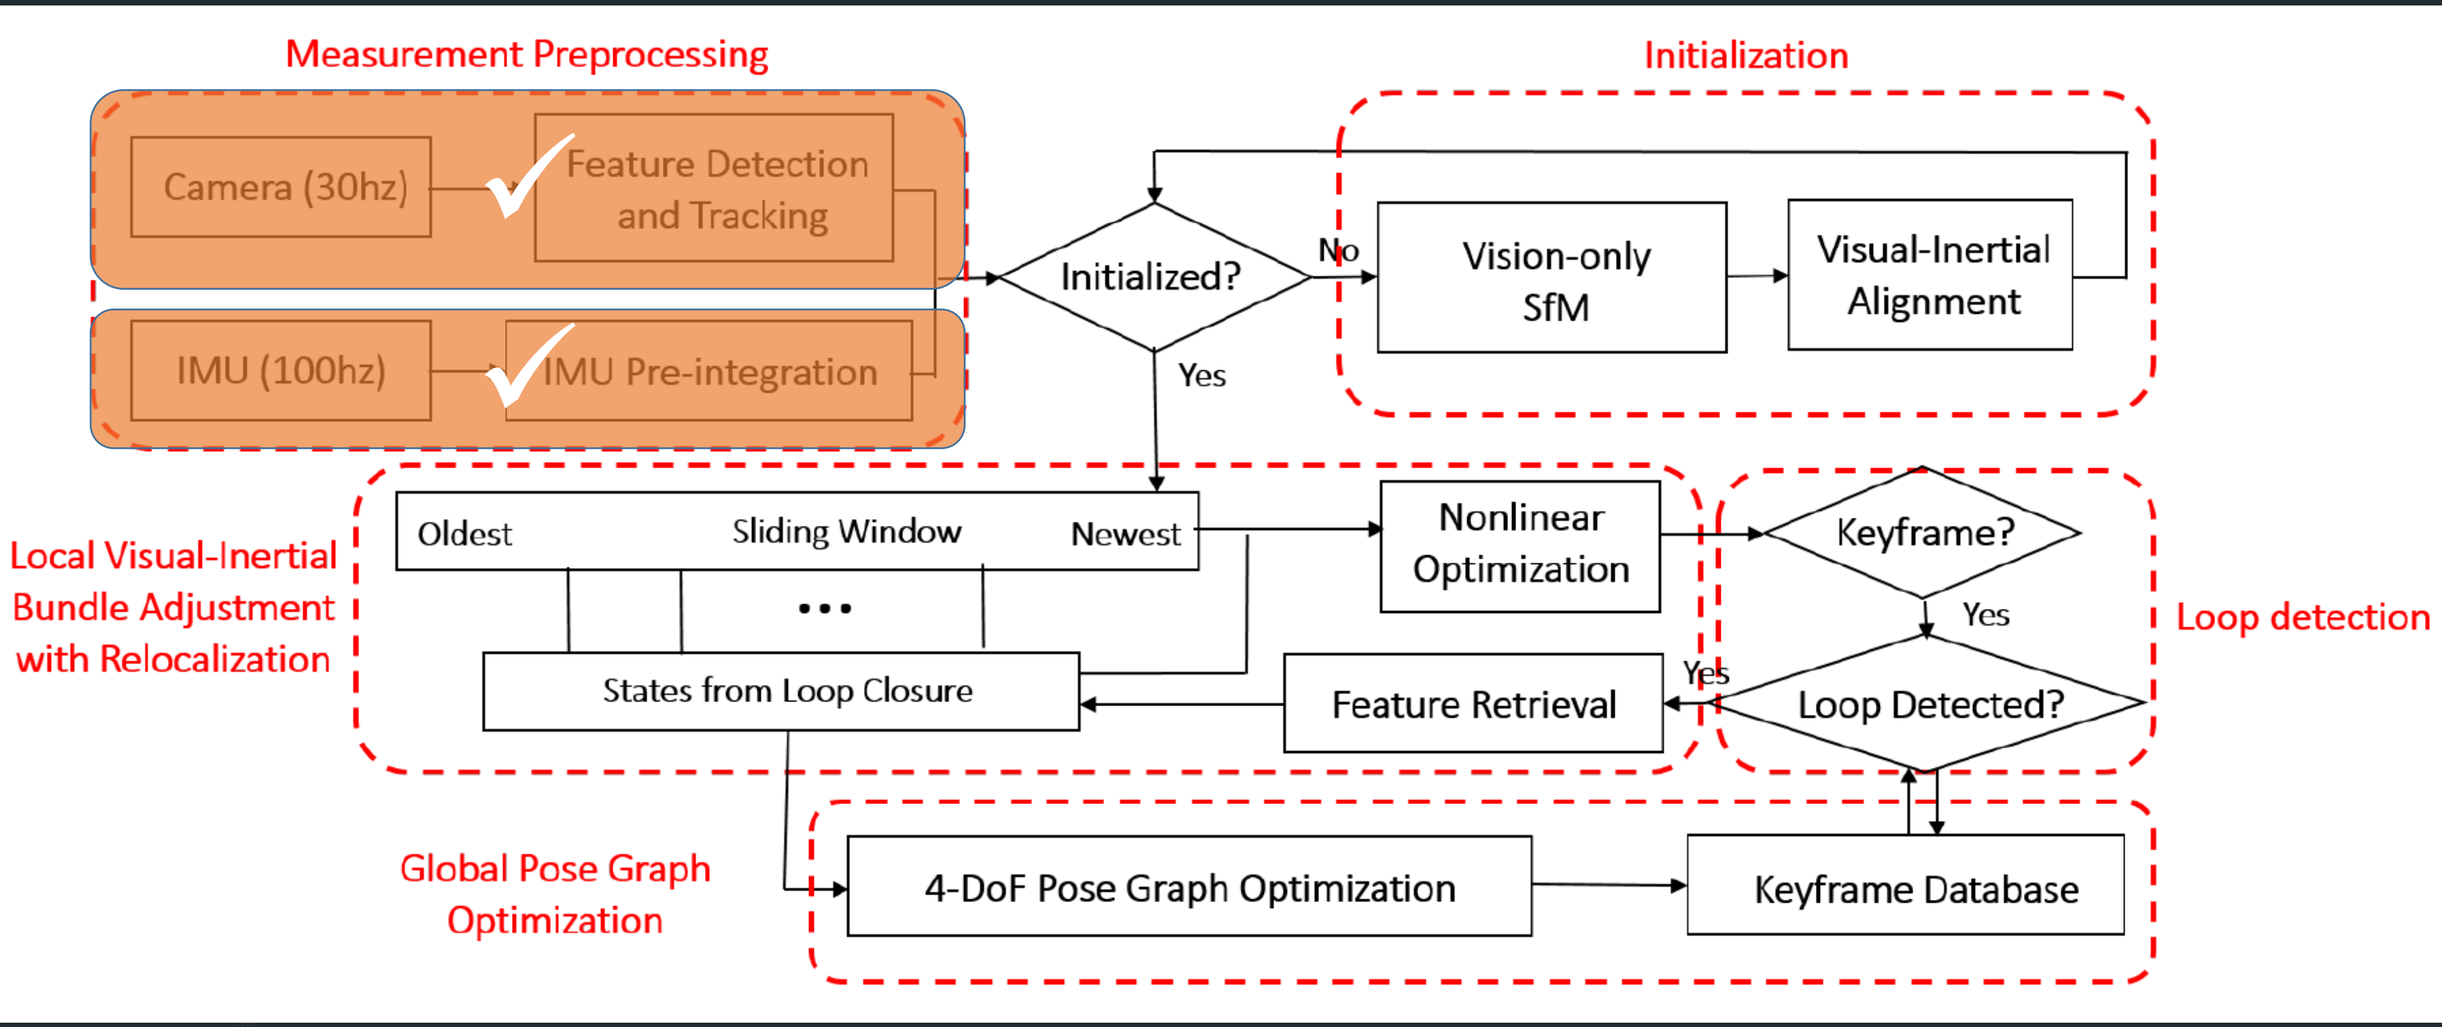
$$Q^{12\times 12} = \begin{bmatrix} \sigma_a^2 & 0 & 0 & 0 \\ 0 & \sigma_w^2 & 0 & 0 \\ 0 & 0 & \sigma_{b_a}^2 & 0 \\ 0 & 0 & 0 & \sigma_{b_w}^2 \end{bmatrix}$$

协方差：$P_{b_{k+1}}^{b_k}$

Jacobian：J_{k+1}

深蓝学院 shenlanxueyuan.com

深蓝学院
shenlanxueyuan.com



深蓝学院
shenlanxueyuan.com

VINS解析——后端非线性优化

优化变量：

滑窗内每帧状态

Cam-IMU外参

滑窗内3D点逆深度

$$X = [x_0, x_1, \cdots x_n, x_c^b, \lambda_0, \lambda_1, \cdots \lambda_m]$$

$$x_k = [p_{b_k}^w, v_{b_k}^w, q_{b_k}^w, b_a, b_g]$$

$$x_c^b = [p_c^b, q_c^b]$$

整体的目标函数：

$$\min_X \left\{ \left\| r_p - H_p X \right\|^2 + \sum_{k \in B} \left\| r_B \left(\hat{z}_{b_{k+1}}^{b_k}, X \right) \right\|_{P_{b_{k+1}}^{b_k}}^2 + \sum_{(l,j) \in C} \left\| r_C \left(\hat{z}_l^{c_j}, X \right) \right\|_{P_l^{c_j}}^2 \right\}$$

边缘化的先验约束

IMU预积分的帧间约束

视觉的重投影误差

VINS解析——后端非线性优化: IMU约束

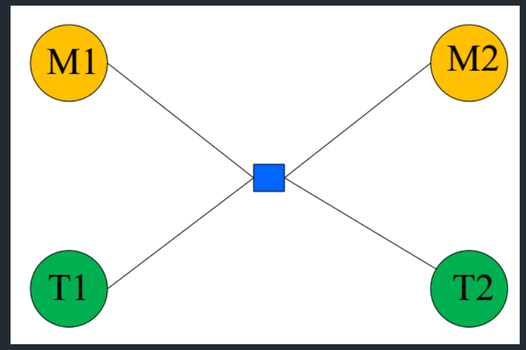
1. IMU误差项：预测值-IMU预积分值

$$r_B\left(\hat{z}_{b_{k+1}}^{b_k}, X\right) = \begin{bmatrix} \delta\alpha_{b_{k+1}}^{b_k} \\ \delta\theta_{b_{k+1}}^{b_k} \\ \delta\beta_{b_{k+1}}^{b_k} \\ \delta b_a \\ \delta b_g \end{bmatrix} = \begin{bmatrix} R_w^{b_k}\left(p_{b_{k+1}}^w - p_{b_k}^w - v_{b_k}^w \Delta t_k + \frac{1}{2} g^w \Delta t_k^2\right) - \alpha_{b_{k+1}}^{b_k} \\ 2\left[\gamma_{b_{k+1}}^{b_k}{}^{-1} \otimes q_{b_k}^w{}^{-1} \otimes q_{b_{k+1}}^w\right]_{xyz} \\ R_w^{b_k}\left(v_{b_{k+1}}^w - v_{b_k}^w + g^w \Delta t_k\right) - \beta_{b_{k+1}}^{b_k} \\ b_{a_{b_{k+1}}} - b_{a_{b_k}} \\ b_{\omega_{b_{k+1}}} - b_{\omega_{b_k}} \end{bmatrix}$$

VINS解析——后端非线性优化: IMU约束

2. 优化变量：

$$[\delta p^w_{b_k}, \delta\theta^w_{b_k}],\ [\delta v^w_{b_k}, \delta b_{a_k}, \delta b_{\omega_k}],$$
$$[\delta p^w_{b_{k+1}}, \delta\theta^w_{b_{k+1}}],\ [\delta v^w_{b_{k+1}}, \delta b_{a_{k+1}}, \delta b_{\omega_{k+1}}]$$



3. Jacobian：

$$J[0]^{15\times7} = \left[\frac{\partial r_B}{\partial \delta p^w_{b_k}}, \frac{\partial r_B}{\partial \delta\theta^w_{b_k}}\right]$$

$$J[2]^{15\times7} = \left[\frac{\partial r_B}{\partial \delta p^w_{b_{k+1}}}, \frac{\partial r_B}{\partial \delta\theta^w_{b_{k+1}}}\right]$$

$$J[1]^{15\times9} = \left[\frac{\partial r_B}{\partial \delta v^w_{b_k}}, \frac{\partial r_B}{\partial \delta b_{a_k}}, \frac{\partial r_B}{\partial \delta b_{w_k}}\right]$$

$$J[3]^{15\times9} = \left[\frac{\partial r_B}{\partial \delta v^w_{b_{k+1}}}, \frac{\partial r_B}{\partial \delta b_{a_{k+1}}}, \frac{\partial r_B}{\partial \delta b_{w_{k+1}}}\right]$$

VINS解析——后端非线性优化: 视觉约束

重投影误差：对于第 l 个路标点 P，将 P 从第一次观看到它的第 i 个相机坐标系，转换到当前的第 j 个相机坐标系下的像素坐标。

1. 第 j 帧的误差项：

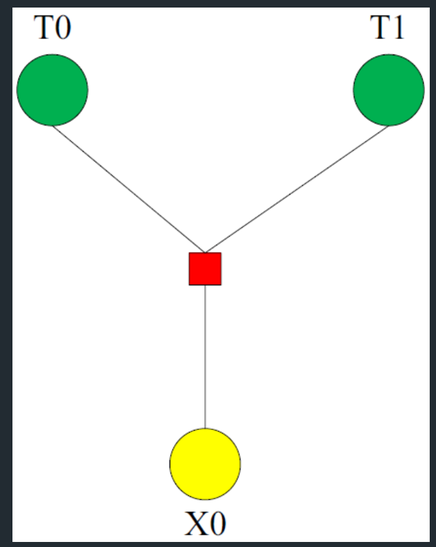
$$r_C\left(\hat{z}_l^{c_j}, X\right) = \begin{bmatrix} \vec{b}_1 \\ \vec{b}_2 \end{bmatrix} \left(\frac{P_l^{c_j}}{\left\| P_l^{c_j} \right\|} - \bar{P}_l^{c_j} \right)$$

其中，第 j 帧预测值：

$$P_l^{c_j} = R_b^c \left\{ R_w^{b_j} \left[R_{b_i}^w \left(R_c^b \frac{1}{\lambda_l} \bar{P}_l^{c_i} + p_c^b \right) + p_{b_i}^w - p_{b_j}^w \right] - p_c^b \right\}$$

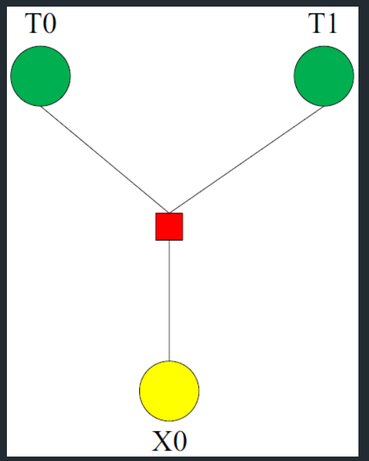
第 j 帧测量值：

$$\bar{P}_l^{c_j} = {\pi_c}^{-1} \left(\begin{bmatrix} \hat{u}_l^{c_j} \\ \hat{v}_l^{c_j} \end{bmatrix} \right)$$



VINS解析——后端非线性优化: 视觉约束

2. 优化变量: $[\delta p_{b_i}^w, \delta\theta_{b_i}^w]$, $[\delta p_{b_j}^w, \delta\theta_{b_j}^w]$, $[\delta p_c^b, \delta\theta_c^b]$, λ_l



3. Jacobian:

$$J[0]^{3\times6} = \left[\frac{\partial r_C}{\partial \delta p_{b_i}^w}, \frac{\partial r_C}{\partial \delta\theta_{b_i}^w}\right] \qquad J[2]^{3\times6} = \left[\frac{\partial r_C}{\partial \delta p_c^b}, \frac{\partial r_C}{\partial \delta\theta_c^b}\right]$$

$$J[1]^{3\times6} = \left[\frac{\partial r_C}{\partial \delta p_{b_j}^w}, \frac{\partial r_C}{\partial \delta\theta_{b_j}^w}\right] \qquad J[3]^{3\times1} = \frac{\partial r_C}{\partial \lambda_l}$$

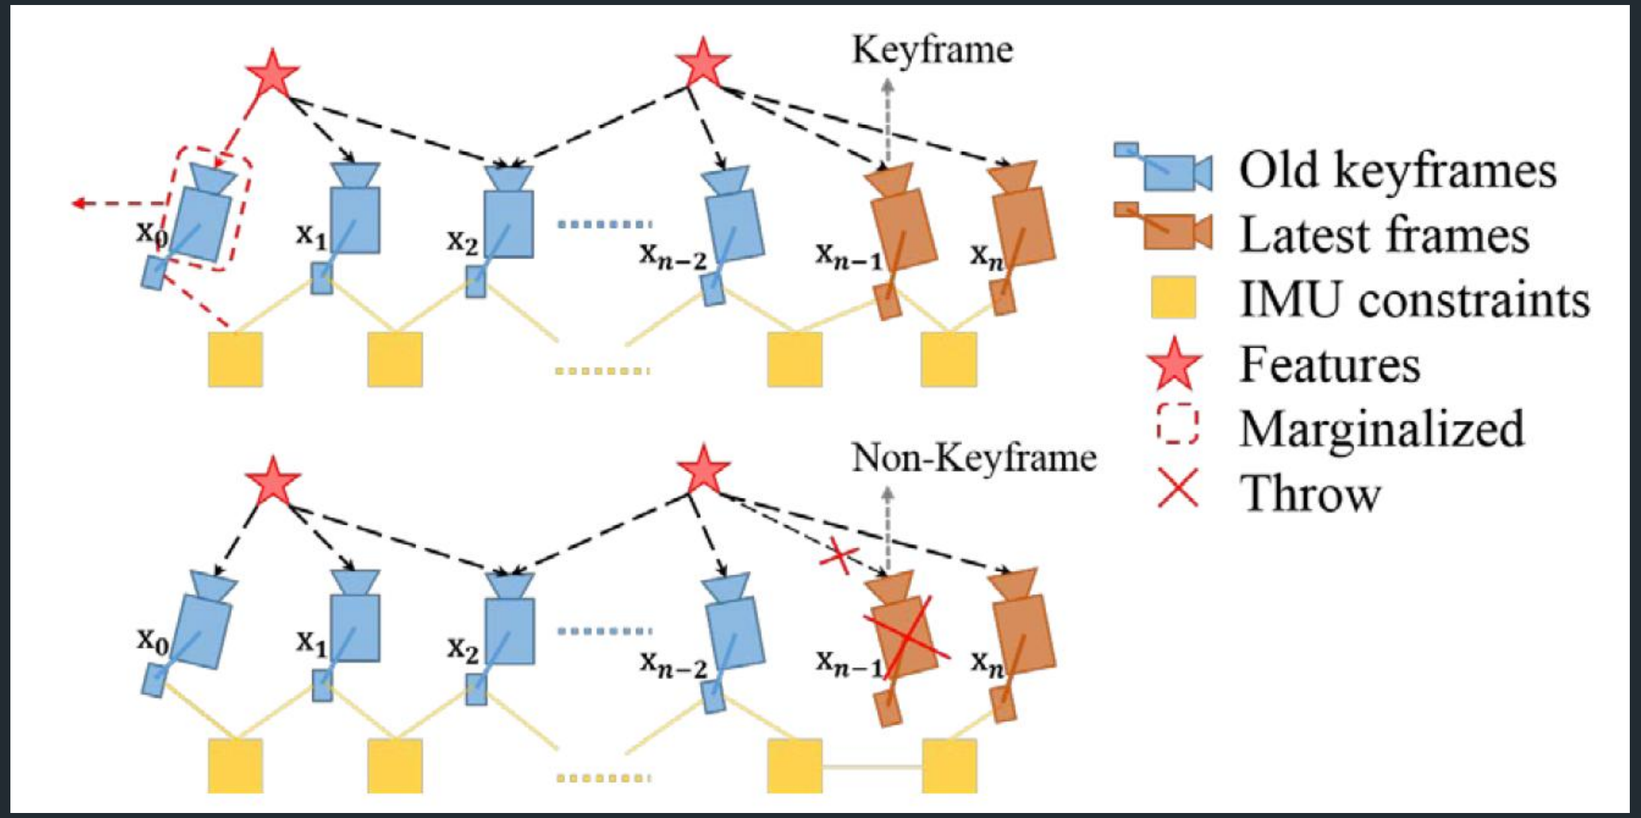
VINS解析——边缘化

目标：

- 控制滑窗大小，从而控制运算量
- 让滑窗中的帧有足够的视差量
- 尽可能使得矩阵稀疏，减小运算量

次新帧为关键帧时，去掉最老帧

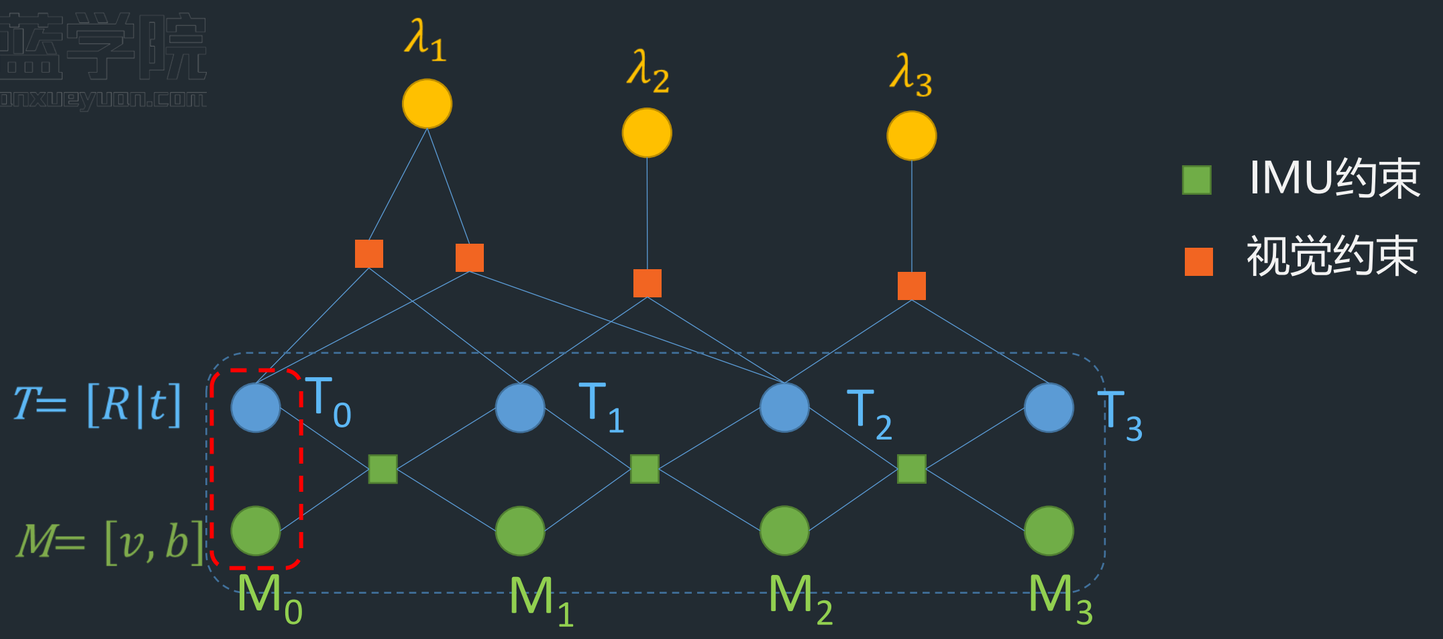
次新帧非关键帧时，去掉次新帧



VINS解析——边缘化约束

首先，将[H|b]矩阵的路标点边缘化掉得到共视矩阵[S|g]，并写成如下形式，其中δx_a、δx_b对应着的是希望边缘化掉的部分（T_0、M_0）和希望保留的部分（T_1、M_1 、T_2、M_2、T_3、M_3 ）：

$$\begin{bmatrix} \Lambda_a & \Lambda_b \\ \Lambda_b{}^T & \Lambda_c \end{bmatrix} \begin{bmatrix} \delta x_a \\ \delta x_b \end{bmatrix} = \begin{bmatrix} g_a \\ g_b \end{bmatrix}$$



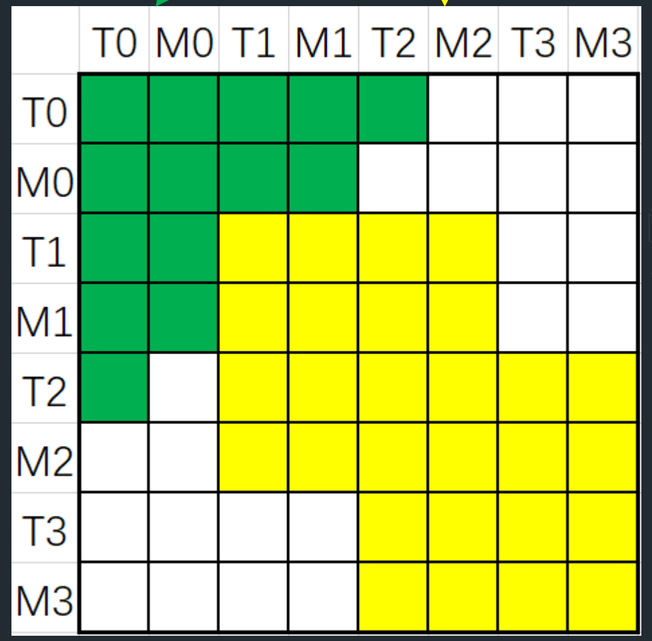
VINS解析——边缘化约束

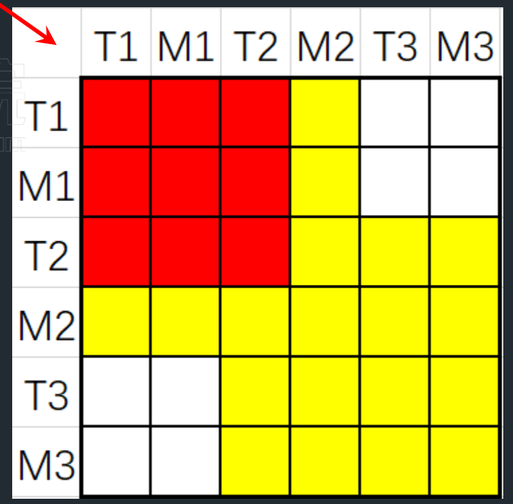
用Schur补公式，来计算最老帧对滑窗内其他帧的约束关系。

$$\begin{bmatrix} I & 0 \\ -\Lambda_b^T\Lambda_a^{-1} & \mathrm{I} \end{bmatrix}\begin{bmatrix} \Lambda_a & \Lambda_b \\ \Lambda_b^T & \Lambda_c \end{bmatrix}\begin{bmatrix} \delta x_a \\ \delta x_b \end{bmatrix} = \begin{bmatrix} I & 0 \\ -\Lambda_b^T\Lambda_a^{-1} & \mathrm{I} \end{bmatrix}\begin{bmatrix} g_a \\ g_b \end{bmatrix} \quad \Leftrightarrow \begin{bmatrix} \Lambda_a & \Lambda_b \\ 0 & \Lambda_c - \Lambda_b^T\Lambda_a^{-1}\Lambda_b \end{bmatrix}\begin{bmatrix} \delta x_a \\ \delta x_b \end{bmatrix} = \begin{bmatrix} g_a \\ g_b - \Lambda_b^T\Lambda_a^{-1}g_a \end{bmatrix}$$

$$\Rightarrow \left(\Lambda_c - \Lambda_b^T\Lambda_a^{-1}\Lambda_b\right)\delta x_b = g_b - \Lambda_b^T\Lambda_a^{-1}g_a$$

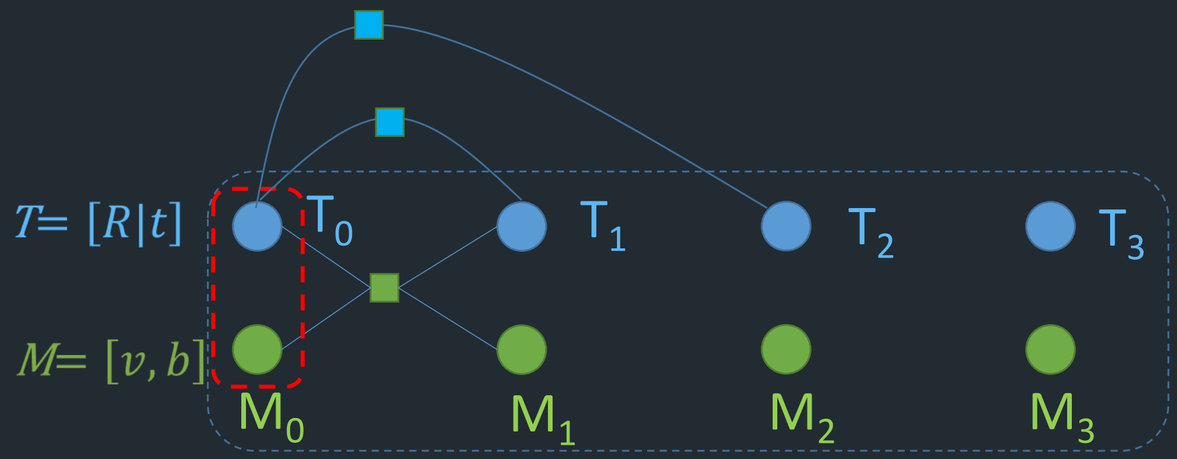
这里并未丢失任何约束，因此不会丢失信息。该式即为要保留变量δx_b的先验信息。

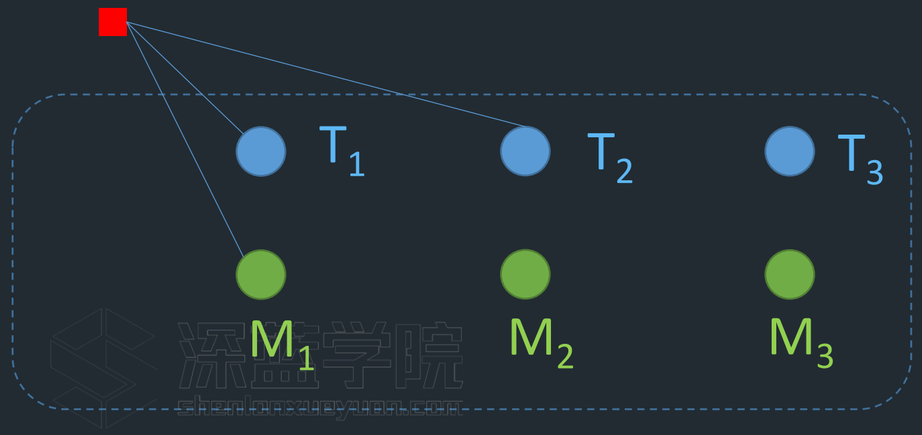


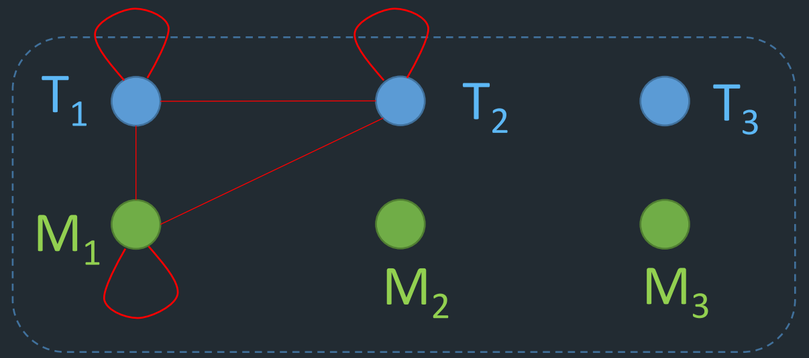


边缘化的因子图解释

marg掉路标点后，只保留跟最老帧相连的因子，然后将最老帧看成一个红色块的因子进行marg



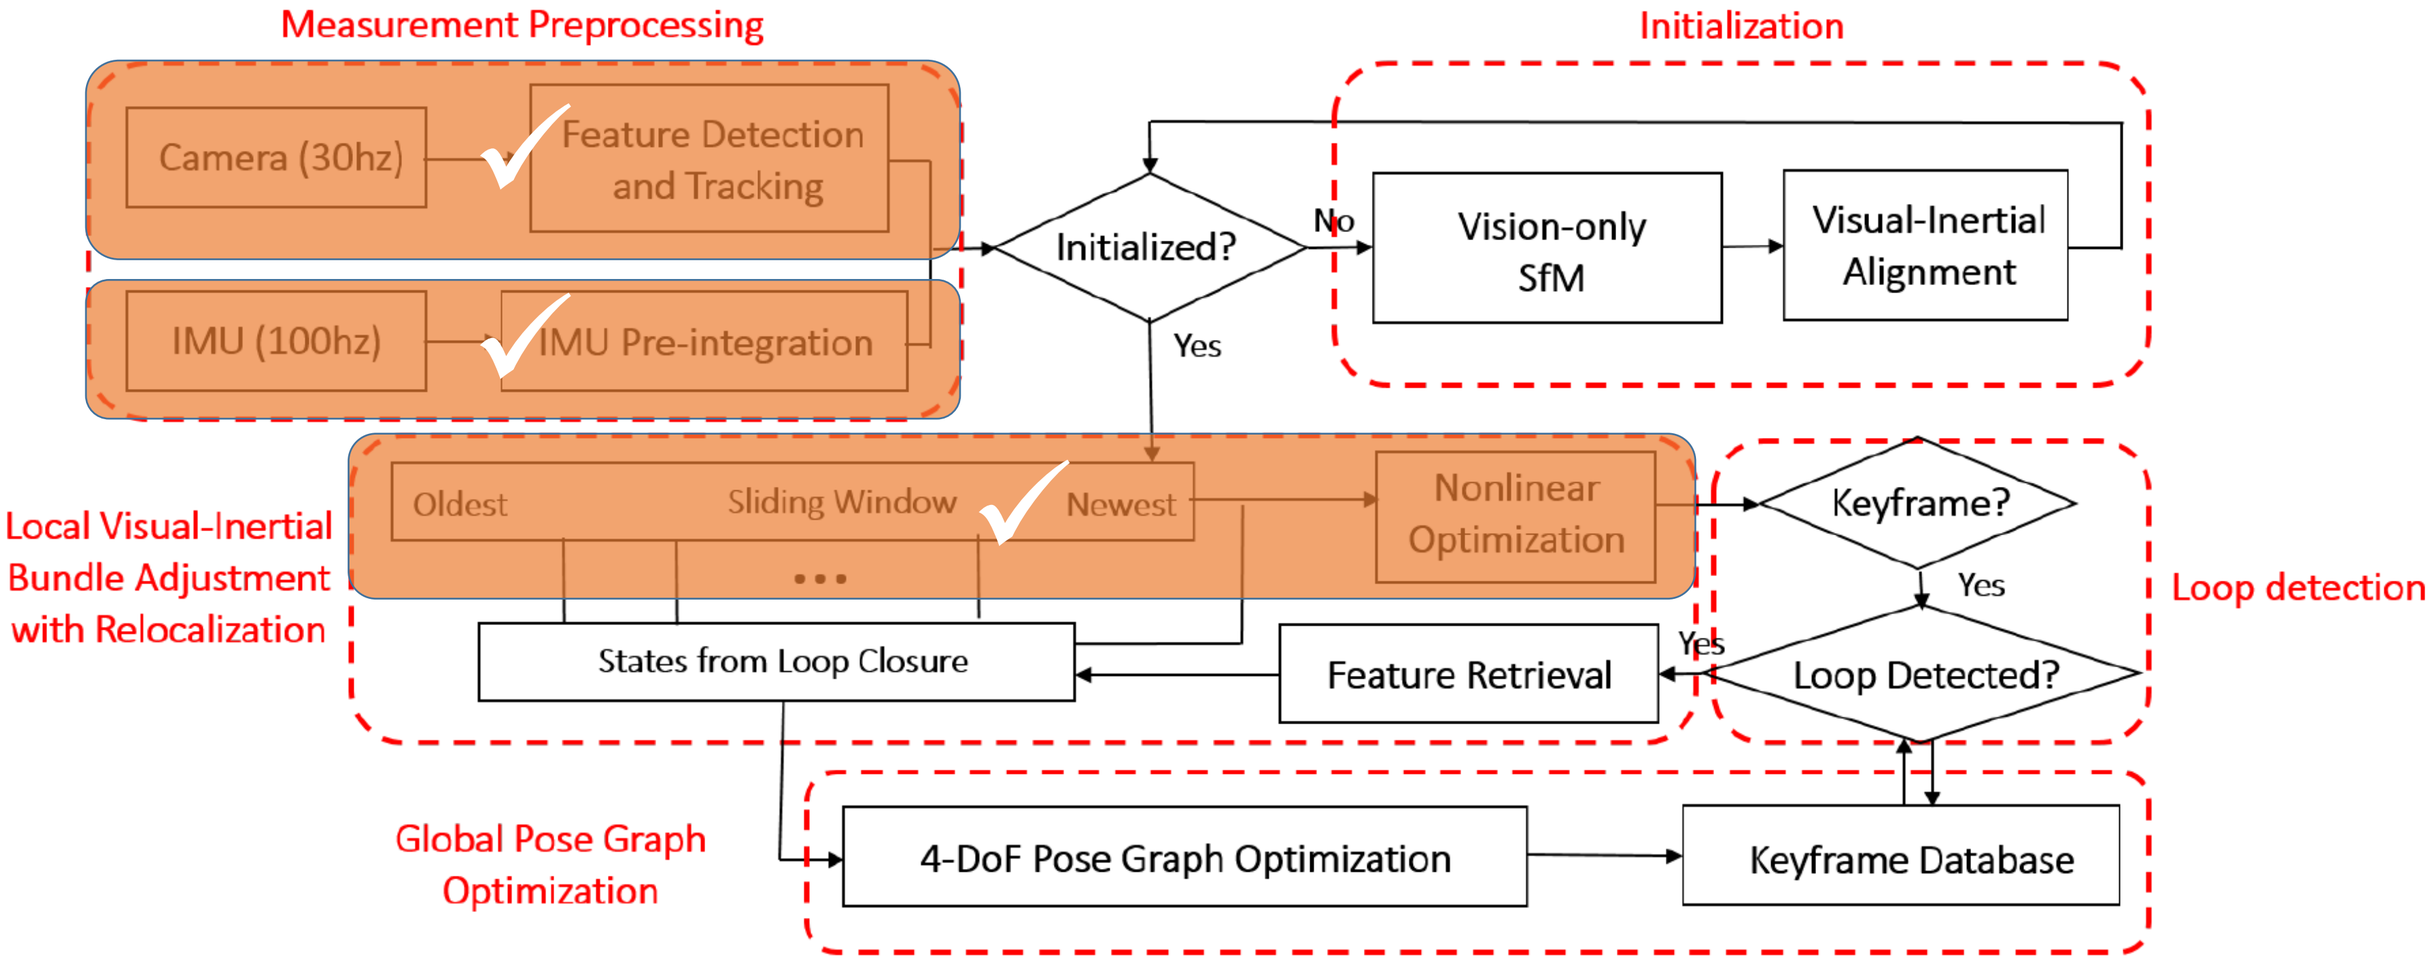




	T1	M1	T2	M2	T3	M3
T1						
M1						
T2						
M2						
T3						
M3						

边缘化产生的新约束

深蓝学院
shenlanxueyuan.com



总结

1 介绍了VIO的意义（视觉和IMU互补）、分类（松紧耦合）；

2 介绍用G-N法建立BA问题的过程，并举了三个例子（一次观测、多次观测、VIO），分别用图形的方式给出对应的Jacobian和Hession；

3 因为数学形式的复杂，引入因子图来形象说明BA问题的建立，并举了三个例子（视觉约束、IMU约束、VIO约束）进行说明；

4 对于目前开源的几个VIO框架（ MSCKF、ROVIO、VINS、VI-ORB、ICE-BA ），用因子图的方式来概况他们的问题是如何建立的；

5 介绍VINS的联合滑窗优化，主要讨论了IMU约束、视觉约束和边缘化的先验约束。详细介绍它们对应的误差项、优化变量、协方差和Jacobian的计算，并对应到代码中进行说明。

深蓝学院
shenlanxueyuan.com

Thanks!